



UNIVERSITÄT ZU LÜBECK  
INSTITUT FÜR  
THEORETISCHE INFORMATIK

## Topic-Modellierung für die Zuordnung von Kundenanfragen zu Sachbearbeitern

*Topic modeling for the assignment of customer inquiries to clerks*

### Bachelorarbeit

verfasst am  
**Institut für Informationssysteme**

im Rahmen des Studiengangs  
**Informatik**  
der Universität zu Lübeck

vorgelegt von  
**Leonard Brenk**

ausgegeben und betreut von  
**Prof. Dr. Ralf Möller**

mit Unterstützung von  
**Dr. Jinghua Groppe, Felix Kuhr, Magnus Bender**

Lübeck, den 1. Oktober 2021

**Eidesstattliche Erklärung**

*Ich erkläre hiermit an Eides statt, dass ich diese Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.*

---

Leonard Brenk

## Zusammenfassung

Täglich werden gewaltige Mengen an Daten erzeugt, die organisiert, gespeichert und verstanden werden müssen. Im Bereich der Analyse von Textdaten, beispielsweise bei der automatischen Zuordnung von Kundenmails auf die jeweils relevante Abteilung, bieten sich Methoden der Topic-Modellierung an. Dabei werden Wörter, die häufig zusammen vorkommen, zu einem Topic - also einem Thema- statistisch gruppiert. Die wohl bekannteste Methode ist die Latent Dirichlet Allocation (LDA), bei der die Dokumente als eine Mischung von verschiedenen Topics und die Topics wiederum als Mischung von verschiedenen Wörtern betrachtet werden. Ein dieser Arbeit zugrunde liegender und mit der LDA-Methode entwickelter Algorithmus soll anhand von Praxisdaten dahingehend überprüft werden, wie die Qualität der Eingangsdaten, das Filter- und Zuordnungsergebnis beeinflusst. Dazu wurden im Rahmen dieser Arbeit mithilfe der LDA-Methode 18 Topics aus über 100.000 Kundenmails generiert und die Überschneidungen mit der jeweils manuell durchgeführten Zuordnung zur relevanten Abteilung verglichen und analysiert. Besonders auffällig war, dass die Zuordnung schlechter war, wenn das Topic aus wenigen Dokumenten bestand. Die Menge der Eingangsdaten ist somit ein relevanter Parameter. Zur weiteren Analyse wurden je Topic die 5 häufigsten Wortnennungen - also die Wörter, die das Topic am stärksten beschreiben - zueinander verglichen. Aufgefallen ist, dass von theoretisch 90 unterschiedlichen Wörtern nur ganze 9 unterschiedliche Wörter vom Algorithmus ermittelt wurden. Diese bestanden zudem häufig aus irrelevanten Begriffen von wiederkehrenden Firmennamen, Begrüßungsformeln und allgemeinen Phrasen, was wiederum die schlechte Qualität der Daten unterstreicht. In der Konsequenz lässt sich feststellen, dass der Bereinigung des Mailcontents bzw. der Daten grundsätzlich eine besondere Bedeutung zukommt, da ansonsten keine eindeutige Mustererkennung und damit keine sinnvolle, automatisierte Zuordnung (Klassifizierung) möglich ist. Ein durchaus leistungsfähiger Algorithmus verliert dadurch an Wirkung bis hin zur Fehlaussage.

## Abstract

Huge amounts of data are generated every day that need to be organized, stored and understood. In the area of text data analysis, for example in the automatic assignment of customer e-mails to the relevant department, topic modeling methods are useful. In this process, words that frequently occur together are statistically grouped into a topic. Probably the best known method is Latent Dirichlet Allocation (LDA), where the documents are considered as a mixture of different topics and the topics in turn as a mixture of different words. An algorithm used in this work and developed with the LDA method is to be examined on the basis of real-life data as to how the quality of the input data influences the filtering and allocation results. For this purpose, 18 topics were generated from more than 100,000 customer emails using the LDA method and the overlaps with the manually performed assignment to the relevant department were compared and analyzed. It was particularly noticeable that the assignment was worse if the topic consisted of only a few documents. The amount of input data is thus a relevant parameter. For further analysis, the 5 most frequent words per topic - i.e. the words that describe the topic most strongly - were compared to each other. It was noticeable that of 90 different words possible, only 9 different words were determined by the algorithm. Moreover, these often consisted of irrelevant terms from recurring company names, greetings and general phrases, which again underlines the poor quality of the data. As a consequence, it can be stated that the cleaning of the mail content or the data is fundamental and of particular importance, since otherwise no clear pattern recognition and thus no meaningful, automated assignment (classification) is possible. A thoroughly efficient algorithm thus loses its effectiveness, even to the point of making a false statement.

# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
1.1	Ziel	2
1.2	Struktur dieser Arbeit	3
<b>2</b>	<b>Grundlagen</b>	<b>5</b>
2.1	Notation	5
2.2	Techniken der Topic-Modellierung	5
2.3	Grundlagen der Latent Dirichlet Allocation	7
<b>3</b>	<b>Konzeption</b>	<b>13</b>
3.1	Verfahrensweise	13
<b>4</b>	<b>Implementierung</b>	<b>17</b>
4.1	Kundenanfragen des ZVO	18
4.2	Datenvorbereitung	19
4.3	Umsetzung Konzept	20
<b>5</b>	<b>Experimentelle Evaluation und Analyse</b>	<b>28</b>
<b>6</b>	<b>Zusammenfassung und Ausblick</b>	<b>38</b>
	<b>Literatur</b>	<b>40</b>



# 1

## Einleitung

Die digitalisierte Welt generiert täglich riesige Mengen an neuen Informationen. Von E-Books, Blogs über Nachrichten-Websites und Magazinen bis hin zu mobilen Anwendungen auf dem Smartphone - immer mehr Menschen verlassen sich auf und richten ihr Leben nach dem Internet aus. Das Zeitalter des Big-Data ermöglicht es Nutzern, unbegrenzt viele Daten zu generieren und zu sammeln. Die Kapazitäten, die ein Mensch aufbringen kann, um solche Massen an Daten zu organisieren und zu verstehen, sind schon lange übertroffen. Vor allem durch die zunehmende digitale Kommunikation und stetig sinkenden Speicherplatzkosten erhöht sich die Menge an zu speichernden Einsen und Nullen. Laut Statista (Tenzer, 2020) wurden im Jahr 2018 33 Zettabyte an Daten generiert mit bis 2025 um 530% einer prognostizierten Steigerung auf 175 Zettabyte. Dieser dramatische Anstieg zeigt die Dringlichkeit für effiziente Algorithmen und Methoden der Datenverarbeitung. Neben der reinen Handhabung solcher Daten steigt aber auch das Bewusstsein, aus diesen Daten Verständnis und Potentiale zu schaffen. Besonders Suchverfahren gewinnen an Bedeutung, wenn in großen, unübersichtlichen Datenmengen bestimmte Informationen gefragt sind. Für die Mehrheit bieten Firmen wie Google diese Anwendung an. Zwar kann durch die keyword-basierte Suche das passende Dokument gefunden werden, jedoch schlägt die Suchmaschine fehl, wenn nach einer Menge von Dokumenten mit einem übergreifenden Thema gefragt wird. Um mehrere Dokumente auf geteilte Themen zu untersuchen, wird die sogenannte Topic-Modellierung verwendet.

Topic-Modellierung (dt. Themenmodellierung) beschreibt eine Gruppe von Verfahren, die es ermöglichen, große elektronische Datensammlungen automatisiert zu durchsuchen, zu organisieren und zu verstehen. Es können Muster innerhalb der Daten erkannt und Topics extrahiert werden. Ein Topic stellt dabei eine Menge an Wörtern dar, die häufig gemeinsam in einem Kontext vorkommen. Einem Topic über Hunde würden beispielsweise die Wörter Bellen, Fell und Halsband zu einer hohen Wahrscheinlichkeit angehören, da sie oft gemeinsam in dem übergeordneten Thema über Hunde gebraucht werden. Die Modellierung solcher Topics wird als Topic-Modellierung bezeichnet, da in einer Datenmenge nach mehreren solcher Topics gesucht wird. Diese können zu unterschiedlichen Anteilen in dem Dokument vertreten sein. Ein Dokument ist dabei ein Teil eines Korpus, also einer Menge mehrerer Dokumente. Dabei stellen Topic-Modelle statistische Modelle dar, die Verwendung in der Inferenz abstrakter Topics in unsortierten

Datenmengen finden. Topic-Modellierung gehört zu dem Bereich des Natural Language Processing, also der Verarbeitung natürlicher Sprache. Es verbindet Computerlinguistik, Informatik und Künstliche Intelligenz, um die Potentiale der Sprachverarbeitung mit der heutigen Technik auszuschöpfen. In einer Welt von exponentiell wachsenden Datenmengen finden Methoden der Topic-Modellierung eine immer breitere Anwendung. Bereits heute wird Topic-Modellierung in vielen Bereichen der Wirtschaft, Wissenschaft und Informationstechnologie verwendet. So findet die Topic-Modellierung unter anderem Anwendung bei Zusammenfassungen, Spam Filtern, Internet of Things (IoT), Healthcare, Blockchain, Chatbots, FAQs oder HR. So wird in (Zamani, Schwartz und Eichstaedt, 2020) mit einem LDA-Modell untersucht, wie ausgeprägt die Sorgen über das Corona Virus sind. Als weiteres Beispiel führt (Mohammed und Al-augby, 2019) eine Studie über eine Menge von E-Books durch, ebenfalls eine Quelle vieler zu verarbeitender Daten. Ein ähnliches Ziel wird in (Anupriya und Karpagavalli, 2015) verfolgt, in dem Abschnitte aus verschiedenen Zeitschriften untersucht und mithilfe einer Topic-Modellierung analysiert werden. Dies zeigt wie umfangreich das Anwendungsspektrum der Topic-Modellierung ist. Weitere Anwendungsgebiete sind in (Chemudugunta, 2010) detailliert beschrieben.

Um semantische Folgerungen aus Datenmengen zu generieren, gibt es verschiedene Ansätze – diese Arbeit wird von der generativen Methode Latent Dirichlet Allocation (LDA) handeln. Dabei werden ähnliche Wörter, die in ähnlichen Kontexten vorkommen, in Topics gruppiert. Die Grundlagen der LDA liegen bei der Verallgemeinerung des bereits 1999 veröffentlichten Probabilistic Latent Semantic Analysis (PLSA). Dieses Verfahren ist in (Hofmann, 1975) erklärt. Im Gegensatz zu anderen Machine Learning Methoden im Bereich der Datenverarbeitung hat Topic-Modellierung die Besonderheit, dass ein Dokument nicht nur zu einem Topic zugeordnet werden kann, wie z.B. bei Clusteralgorithmen. Bei der Topic-Modellierung wird jedes Dokument durch eine Verteilung an Topics beschrieben. Das bedeutet, in jedem Dokument sind immer alle Topics zu finden – nur zu einem bestimmten Anteil. Genauso sind in einem Topic immer alle Wörter zu einer bestimmten Wahrscheinlichkeit vorhanden. Bei einem Artikel, der zu 90% von Sport und zu 10% von Politik handelt, werden somit neun mal mehr Wörter bezüglich Sport zu finden sein, als zu Politik. Topic-Modellierung wird den unüberwachten Lernmethoden des Data Minings zugeordnet, also der Extraktion von Mustern und Trends in Datenmengen durch die Anwendung statistischer Algorithmen. Das bedeutet, dass die Topics ohne die Einwirkung von manuell erzeugten Labels gefunden werden. Im Lernprozess werden dann Verteilungen basierend auf den bislang vorgenommenen Zuordnungen iterativ angepasst und verbessert – jedoch alles ohne menschliches Zutun.

### 1.1 Ziel

Diese Arbeit wird die Theorie der Topic-Modellierung anhand des Beispiels des Zweckverband Ostholstein (ZVO) in der Praxis implementieren und die bezüglichen Parameter im Sinne des ZVO bewerten. Der ZVO ist ein Unternehmensverbund, der in Norddeutschland in der Energie-, Entwässerungs-, Internet- und Entsorgungsbranche tätig ist. Er erhält jährlich eine große Menge an Kundenanfragen, die von Mitarbeitern gelesen und



klassifiziert werden. Die klassifizierte Kundenanfrage wird dann an die zuständige Abteilung weitergeleitet. Dieser Vorgang ist sowohl zeitintensiv als auch fehleranfällig und führt zu einer Ineffizienz in der Wertschöpfungskette. Der Prozess soll zukünftig automatisch durch einen Klassifikationsmechanismus funktionieren.

Diese Arbeit verfolgt zwei Ziele:

1. Vorhersage der Qualität der Klassifikation durch Untersuchung der Datenqualität
2. Analyse der vordefinierten Abteilungen durch Topiczuordnung

Diese Arbeit beschäftigt sich mit der Vorhersage der Qualität des Klassifikators, indem die Qualität der manuell erstellten Kategorien und Kundenanfrage-Gruppen untersucht und mit den Ergebnissen verschiedener Topic-Modellierungen verglichen wird. Zum Beispiel ist die Größe der Korpora, also der Menge an zu untersuchenden Dokumenten, ein bedeutendes Element der Modellierung, womit sich (Řehůřek und Sojka, 2010) beschäftigt. Das Ergebnis eines Topic Models hängt ebenfalls stark von der Qualität der Daten ab, die es als Input bekommt. Diese Daten durchlaufen eine Reinigungsphase, bevor sie klassifiziert werden, um sie in eine gut zu verarbeitende Form zu bringen. Der Prozess der Reinigung kann Einfluss auf das Ergebnis haben. Ziel dieser Arbeit ist es, Erkenntnisse über die Qualität des Klassifikators in Abhängigkeit zu den verwendeten Daten zu treffen. Somit wird durch die Nutzung von LDA-Modellen die Qualität der Daten untersucht. Detaillierte Informationen sind in (*KI in der Kundenkommunikation*) zu finden.

### 1.2 Struktur dieser Arbeit

Der Bereich Data Science und Datenverarbeitung durchläuft aktuell eine starke Welle an Innovation und Veränderung. Deshalb wird in dieser Arbeit zuerst eine Einleitung die Motivation und das Prinzip der Topic-Modellierung beschreiben. Gefolgt wird die allgemeine Einleitung von der Motivation und Aufgabenstellung in Bezug auf das Anwendungsbeispiel des Zweckverbands Ostholstein (ZVO). Die Anwendung der Algorithmen wird im Laufe der Arbeit mit theoretischen Grundlagen erklärt, die eine klare Notation fordern: diese ist im Teil der Notationen gelistet. Das Prinzip der Topic-Modellierung kann mit unterschiedlichen Ansätzen implementiert werden. Beispiele sind: LDA und LSA. Da sich diese in ihrem Ansatz und in ihrer Umsetzung unterscheiden, werden im nächsten Abschnitt die bekanntesten Methoden verglichen, indem ihre Vorgehens- und Funktionsweisen untersucht werden. Die Methode, die in dieser Arbeit genauer beleuchtet wird, ist die Latent Dirichlet Allocation. Der dritte Abschnitt wird von der Herkunft, dem Format und der Verarbeitung der Daten des ZVO handeln. Dabei werden sowohl der Anwendungsfall und der ZVO genauer erklärt, als auch ein Einblick in die Daten, deren Reinigung und Verarbeitung gegeben. Darauf folgt das Konzept der Lösungsstrategie, um die Aussagekraft und Qualität der Daten für Topic-Modellierung erfolgreich zu untersuchen. Dafür wird der Ablauf des Algorithmus anschaulich dargestellt und die Prozesskette der Analyse im Detail aufgeschlüsselt. Im vierten Abschnitt findet die Implementierung des im dritten Abschnitt erklärten Konzepts statt. Für diese wird eine Methode der Topic-Modellierung ausgewählt und in einer Programmierumgebung realisiert. Die

Umsetzung wird anhand des gelisteten Algorithmus zeilenweise erklärt. Der Output ist in die Arbeit integriert, um dessen zentrale Rolle in der Datenanalyse zu unterstreichen und die Ergebnisse verständlich begründen zu können. Die detaillierte Analyse folgt im nächsten Abschnitt, der sich damit befasst, die Ergebnisse der Implementierung im Anwendungsfall des ZVO zu interpretieren. Dabei wird begründet, wie gut sich die Daten für eine Topic-Modellierung eignen und was die Ergebnisse über die Qualität der Daten aussagen. Die Arbeit wird abgeschlossen mit der Zusammenfassung und einem Ausblick für den ZVO in Bezug auf Topic-Modellierung. Die gewonnenen Ergebnisse der Datenqualität sollen dem ZVO nach der Ergebnisgewinnung zu einer höheren Effizienz in der Datenverarbeitung verhelfen und Aufschluss über Handlungsbedarf und Optimierungspotential in den Datensätzen geben.

# 2

## Grundlagen

In diesem Kapitel werden die grundlegenden Eigenschaften von Topic-Modellierung erklärt. Dabei wird auf die verschiedenen Methoden Bezug genommen und Parameter erklärt, die beeinflussen können, wie eine Methode Topics erkennt und klassifiziert. Topic-Modellierung wird schon seit vielen Jahren verwendet und hat viele Veränderungen durchlaufen. Diese Arbeit wird im folgenden Kapitel auf die wichtigsten Entwicklungsmeilensteine eingehen.

### 2.1 Notation

Für das Verständnis von Topic-Modellierung ist es wichtig die Begriffe zu kennen und zu verstehen. Dabei sind Wörter bekanntermaßen Mengen aus beliebigen Buchstaben. Mehrere Wörter bilden zusammen ein Dokument. Mehrere Dokumente werden als Korpus bezeichnet. Dokumente können Topics, also Themenbereiche, zu unterschiedlichen Anteilen abdecken. Topic-Modellierung versucht diese Topics aus Dokumenten zu extrahieren.

- Ein Wort wird mit  $w \in N$  mit  $N$  als Menge aller Wörter bezeichnet
- Eine Menge Wörter ergeben ein Dokument  $d \in D$  mit  $D$  als Menge von Dokumenten
- Eine Menge an Dokumenten ergibt einen Korpus  $D$
- Eine Menge an Wörtern ergibt ein Topic  $z \in K$  mit  $K$  als Menge aller Topics
- Ein Topic-Modell wird mit  $M$  beschrieben

### 2.2 Techniken der Topic-Modellierung

Das Feld des Information Retrievals bietet vielseitige Verfahren, um Topic-Modellierung zu betreiben. Bei vielen geht es um eine Dimensionsreduktion des Datensatzes, die Aufschluss und Erkenntnis über die Datenmenge geben soll, indem diese in eine weniger komplexe Darstellungsform umgewandelt wird. In dieser Arbeit wird die Latent Dirichlet Allocation (LDA) verwendet, die als Bindeglied zwischen statistischen und probabilistischen Methoden agiert. LDA wurde durch die Optimierung und Vermischung verschiedener vorangegangener Verfahren entwickelt. Die wichtigsten Verfahren in der

Entwicklung von Techniken der Topic-Modellierung sind im Folgenden aufgelistet und erklärt:

### **Term Frequency - Inverse Document Frequency(Tf-idf)**

Das Verfahren der Tf-idf beschreibt ein statistisches Maß, um die Wichtigkeit von Wörtern in einer Gruppe von Dokumenten zu beurteilen. Die Term-Frequency(Tf) erstellt eine Matrix, die die Anzahl der Wörter auf die Dokumente abbildet, in denen sie enthalten sind. Um zu vermeiden, dass Wörter, die wenig Aussagekraft für den Korpus haben, (wie z.B. das Wort „und“,) das Ergebnis verzerren, bestimmt die Inverse Document Frequency(idf), wie spezifisch ein Wort für einen gesamten Korpus ist. Das einzelne Dokument ist dafür demnach nicht mehr wichtig. Die Idee dabei ist, dass Wörter, die sehr selten vorkommen, ein Dokument unter Umständen stärker beeinflussen können als ein Wort, das so häufig vorkommt, dass es schon keine Aussagekraft oder semantische Relevanz mehr hat. Das Verfahren verwendet keine probabilistischen Elemente, sondern ist eine rein statistische Möglichkeit, um herauszufinden, wie wichtig ein Wort eines Dokuments für das Gesamtthema des Dokuments ist.

### **Latent Semantic Analysis**

Viele Verfahren der Topic-Modellierung gehen auf die sogenannte Latent Semantic Analysis (LSA) zurück. LSA baut auf dem Prinzip der Tf-idf auf, indem es die Tf-Matrix nutzt und adaptiert. Bei dem Verfahren geht es um das Finden sogenannter Hauptkomponenten in Dokumenten. Grob können Hauptkomponenten als allgemeine Überthemen verstanden werden. So wäre Politik die Hauptkomponente, die von Wörtern wie Politiker, Bundestag und Regierung beschrieben wird. Mathematisch gesehen verbindet man mit der Hauptkomponente die Hauptkomponentenanalyse, die als statistische Methode versucht, viele Variablen mithilfe von Eigenvektoren und Kovarianzen in einer vereinfachten Form mit einem möglichst geringen Informationsverlust darzustellen. Dabei ist das Ziel, die Tf-Matrix möglichst verkleinert darzustellen, die die Anzahl der Vorkommen für jedes Wort pro Dokument abbildet. Sie wird in Matrizen aus Eigenvektoren und Eigenwerten aufgespalten, wodurch es möglich ist, die wichtigen Hauptkomponenten aus der meist sehr großen Tf-Matrix zu extrahieren. Diese Matrix wird als Produkt dreier Matrizen dargestellt, von denen die mittlere eine Diagonalmatrix darstellt. Anhand der Werte auf der Diagonalen lassen sich die Topics der Textmenge ablesen. LSA stellt sich als ein attraktives Verfahren heraus, da es Synonyme besser erkennen kann als LDA und wird heutzutage unter anderem intensiv in dem Bereich des Digital Marketings genutzt. Die Studie (Mohammed und Al-augby, 2019) beschreibt einen Vergleich zwischen LSA und LDA.

### **Probabilistic Latent Semantic Analysis**

Probabilistic Latent Semantic Analysis (PLSA) verfolgt den Ansatz, ein Wahrscheinlichkeitsmodell zu finden, das ein Dokument erzeugt, das zu der Tf-Matrix passt. PLSA hat als erste Methode dem Konzept der Topic-Modellierung Wahrscheinlichkeiten hinzugefügt. Dabei sind das Dokument und Wort bekannt, das assoziierte Topic jedoch nicht.

Der grundlegende Gedanke ist, dass ein Dokument generiert werden kann, indem zuerst das Dokument mit einer bestimmten Wahrscheinlichkeit gewählt wird, dann ein Topic und aus diesem Topic dann ein Wort - alles mit Wahrscheinlichkeiten beschrieben. Es lässt sich der Fall, dass Dokument  $d$  über Topic  $z$  handelt, mit einer Wahrscheinlichkeit von  $P(z | d)$  beschreiben. Dazu berechnet  $P(w | z)$ , wie wahrscheinlich es ist, dass das Wort  $w$  aus einem gegebenen Dokument  $d$  zu Topic  $z$  gehört. Somit führt PLSA die Gesamtwahrscheinlichkeit ein, dass ein Wort in einem gegebenen Dokument zu finden ist:  $P(D, W) = P(D) \sum_Z P(Z | D) P(W | Z)$ .

### Latent Dirichlet Allocation

Basierend auf LSA und PLSA ergibt sich eines der meist verbreiteten Verfahren: Latent Dirichlet Allocation (LDA). Dieses Verfahren ist sehr ähnlich zu PLSA, das durch zwei Dirichlet-Verteilungen ergänzt wurde. LDA liegt, genau wie PLSA, ein generierender Prozess zugrunde, der jedes Dokument basierend auf mehreren Wahrscheinlichkeitsverteilungen generieren kann. Dabei wird zuerst das Dokument  $d$  mit  $P(d)$ , für dieses dann ein Topic  $z$  mit  $P(z | d)$  und anschließend die Wörter  $w$  mit  $P(w | z)$  gewählt. Grundsätzlich werden Dokumente bei LDA in Form der Dokument-Topic-Verteilung dargestellt, die die Ausprägungen verschiedener Topics in einem Dokument beschreibt. Für die Topics gibt es die Topic-Word-Verteilung, die die Wahrscheinlichkeit beschreibt, mit der ein bestimmtes Wort in einer gewissen Regularität in einem Topic vorkommt. Dabei geht man davon aus, dass ein Dokument eine Verteilung von Topics ist, während ein Topic als eine Verteilung über Wörter betrachtet wird. Der Unterschied zu PLSA liegt in dem Hinzufügen von zwei besonderen Verteilungen, die die Zuordnung von Dokumenten zu Topics maßgeblich beeinflussen: die Dirichlet Verteilungen. Die genaue Erklärung folgt im nächsten Abschnitt. Die Wahrscheinlichkeit, dass ein bestimmtes Dokument generiert wird, ist das Produkt der Wahrscheinlichkeiten der Dokument-Topic-Verteilung und Topic-Word-Verteilung mit den Wahrscheinlichkeiten der zwei hinzugefügten Dirichlet-Verteilungen. So werden erst die Topics zufällig ausgewählt, wie in der Dirichlet-Verteilung definiert, und aus diesen daraufhin mithilfe der zweiten Dirichlet-Verteilung Wörter aus diesen Topics hergeleitet, wodurch das Enddokument entsteht. Die Herangehensweise ist in der Realität meistens umgekehrt, da selten Dokumente auf Basis bekannter Topics generiert werden müssen, sondern eher Topics von bekannten Dokumenten gefunden werden sollen. LDA bietet die Grundlage für viele andere Verfahren. So verwendet (Ahuja, Wei und Carley, 2015) eine erweiterte Form von LDA, indem die sogenannten Social Media Topic Models eingeführt werden. Bei diesen werden Wörter und Hashtags separat voneinander als Input für das Modell verwendet. David M. Blei beschreibt das Prinzip der LDA in seinem Paper (Blei, Ng und Jordan, 2003) und vergleicht es mit anderen Modellierungen, wie LSA und pLSA.

### 2.3 Grundlagen der Latent Dirichlet Allocation

Latent Dirichlet Allocation (LDA) ist ein grundlegendes und bekanntes Verfahren aus der maschinellen Verarbeitung natürlicher Sprachen. Genauere Informationen dazu können

in (Jelodar, Wang und Yuan, 2019) gefunden werden. Die Wichtigkeit von LDA wird auf der Komplexität der damals bestehenden Techniken der Textverarbeitung begründet. So waren Clusteralgorithmen zu starr in ihrem Anwendungsumfeld, während Dimensionsreduktionen, wie die Hauptkomponentenanalyse von LSA, Ergebnisse lieferten, die sehr schwer zu interpretieren waren. In dieser Arbeit wird LDA zur Verarbeitung der Daten verwendet, da es sich in der Vergangenheit als effektiv bewiesen hat und für die Aufgabenstellung dieser Arbeit gut geeignet ist. Das Prinzip der Topic-Modellierung basiert auf einer Menge an Dokumenten, die den Korpus darstellen. Dabei werden bei LDA alle Dokumente als Menge von Wörtern angenommen. Diese sind als sogenannter Bag of Words modelliert. Das bedeutet, dass die Wörter als Menge ohne Reihenfolge interpretiert werden und nur die Häufigkeit der Begriffe in dieser Menge relevant ist. LDA ist ein generatives Modell, das durch unterschiedliche Einflussgrößen, wie in Abbildung 2.1 dargestellt, Dokumente erstellen kann.

Erläuternd für die Namensgebung steht „Latent“ für alles, was im Vorhinein unbekannt ist. Im Fall LDA handelt es sich um jene Themen, welche in einem Dokument zu einem bestimmten Teil vertreten sind. „Dirichlet“ beschreibt eine Verteilung von Verteilungen. Bei der Topic-Modellierung bedeutet Dirichlet eine Verteilung von Topics in Dokumenten und eine Verteilung von Wörtern in Topics. Die Dirichlet-Verteilungen sind die ausschlaggebende Veränderung im Vergleich zu PLSA. Durch sie kann die Stärke der Ausprägung der Topics in der Dokument-Topic-Verteilung und der Wörter in der Topic-Word-Verteilung bestimmt werden. Die „Allocation“ weist mithilfe der errechneten Dirichlet-Verteilungen Dokumenten Topics und Topics Wörter zu. Eine Besonderheit bei der Topic-Modellierung mit LDA ist, dass die Anzahl der gesuchten Themen  $K$  vorgegeben werden muss. Oft ist diese vorher jedoch nicht bekannt und muss über Hilfsverfahren, wie dem der Perplexitätsberechnung ermittelt werden. Dabei wird gemessen, wie geeignet das Modell für die Verarbeitung der gegebenen Daten ist. Die Funktionsweise von LDA ist über folgende graphische Abbildung beschrieben:




Abbildung 2.1: Graphische Darstellung von LDA

Dabei beschreibt  $w$  als einzige nicht verborgene Variable eines von  $|N|$  Wörtern des

Dokuments. Das Wort ist semantisch einem Thema  $z$  zugeordnet. Das Thema wiederum hängt von der Dokument-Topic-Verteilung  $\theta$  des Dokuments ab, das als ein Element der  $|D|$  vorliegenden Dokumente betrachtet wird. Ebenfalls ist das Wort von der Topic-Word-Verteilung  $\phi$  abhängig. Bei LDA werden zwei Verteilungen aus den Dokumenten  $d \in D$  und  $k \in K$  gelernt:

- die Dokument-Topic-Verteilung  $\theta_d$ , die angibt, mit welcher Wahrscheinlichkeit das Dokument zu jedem Themen gehört und
- die Topic-Word-Verteilung  $\phi_k$ , die die Wahrscheinlichkeit berechnet, mit der ein Wort einem Thema angehört

$M = \text{LDA}(D)$  beschreibt ein LDA Modell, das auf dem Korpus  $D$  trainiert wurde. Das Modell und dessen Verteilungen können durch die Parameter  $\alpha$  und  $\beta$  angepasst werden.  $\alpha$  bestimmt die Intensität der Dokument-Topic-Verteilung, während  $\beta$  die der Topic-Word-Verteilung beeinflusst. Bei einem großen  $\alpha$  ist die Verteilung der Topics in einem Dokument ähnlicher. Bei LDA werden zwei widersprüchliche Bedingungen verfolgt, die von den beiden Parametern beeinflusst werden können:

1. Es wird für alle Wörter eines bestimmten Dokuments nach so wenig zugeordneten Topics wie möglich gestrebt
2. Ein Topic soll über so wenig relevante Wörter wie möglich verfügen

Die beiden Ziele stehen in einer Wechselbeziehung zueinander, da eine minimale Anzahl an vertretenen Topics in einem Dokument zu maximal vielen Wörtern in diesen Topics führt. Die minimale Anzahl an Topics wäre erreicht, wenn man alle Wörter eines Dokuments einem Topic zuweisen würde. Dann verfügt das Topic jedoch über alle Wörter des Dokuments.  $\alpha$  befindet sich in dem Bereich  $[0, 1]$  mit sinnvollen Werten zwischen  $[0.01, 0.1]$ , während  $\beta = 0.01$  durchschnittlich die besten Ergebnisse liefert, wie (Bender, 2019) beschreibt. Große Werte führen zu einer Gleichverteilung, die wiederum eine Verschlechterung der Perplexität bedeutet. Somit bietet die Perplexität ein Mittel, um  $\alpha$  und  $\beta$  optimal mit Werten für die individuelle Anwendung zu belegen. Mehr Details zu Topic-Modellierung und dessen theoretischen Grundlagen sind in (Doll, 2018) zu finden.

### Der generative Prozess

Bei der Erstellung eines Klassifikators gibt es zwei unterschiedliche Herangehensweisen: den diskriminativen und den generativen Ansatz. Bei der diskriminativen Methode werden Vorhersagen für die unbekannten Daten auf der Grundlage der bedingten Wahrscheinlichkeit gemacht. Es wird kurz gesagt die Grenze zwischen zwei Klassen errechnet. Im Gegensatz dazu konzentriert sich ein generatives Modell auf die Verteilung eines Datensatzes, um eine Wahrscheinlichkeit für ein bestimmtes Beispiel zu ermitteln. Betrachtet man zwei Variablen, ein bekanntes  $X$  und eine gesuchte Variable  $Y$ , dann wird im deskriptiven Modell die bedingte Wahrscheinlichkeit  $P(Y | X)$  betrachtet. Im Gegensatz dazu ist bei generativen Modellen die Wahrscheinlichkeit von  $X$  und  $Y$  gemeinsam relevant, also  $P(X, Y)$ . Bei generativen Modellen besteht die Möglichkeit, Ausgabeinstanzen zu erstellen. Bei LDA handelt es sich um einen generativen Algorithmus. Das bedeutet nicht direkt, dass LDA bei der Ausführung aktiv neue Dokumente entwickelt, sondern stellt eine



Erklärung dafür dar, wie die Zusammenstellung der Topics und deren Wörter in einem spezifischen Fall entstanden sein könnten. Es könnten theoretisch im Fall einer neuen Dokumentenzuordnung zu Abteilungen für jede Abteilung zufällig Dokumente generiert werden. Diese würden zufällig gewählte Wörter basierend auf der Topic-Verteilung aneinanderreihen und mit hoher Wahrscheinlichkeit keinen Sinn ergeben. Trotzdem könnten diese Dokumente mit den Dokumenten der Abteilungen verglichen und auf Ähnlichkeit geprüft werden. Dann könnten die Parameter solange angepasst werden, bis das Ergebnis akzeptabel ist. Der reguläre Weg ist jedoch entgegengesetzt: Man sucht nicht das Dokument zu einer gegebenen Dokument-Topic-Verteilung und einer Topic-Word-Verteilung, sondern hat das Dokument bereits und sucht die Verteilungen. Den generativen Prozess von LDA beschreibt (AlSumait u. a., 2009) im Detail. Es wird ein Modell gelernt, das den gegebenen Korpus am wahrscheinlichsten nach folgender Vorgehensweise generiert haben könnte. Dabei sei  $Dir(\alpha)$  eine Dirichletverteilung, welche einen Parameter  $\alpha$  bzw.  $\beta$  übergeben bekommt und  $Multinom(\theta_d)$  eine Multinomialverteilung mit dem Parameter  $\theta$  bzw.  $\phi$ . Bei der Berechnung ergibt sich der Output durch die dann berechneten Wahrscheinlichkeitsverteilungen  $\theta_d$  und  $\phi_k$ .

1. Wähle ein  $\theta_d$  als  $Dir(\alpha)$
2. Wähle ein  $\phi_k$  als  $Dir(\beta)$
3. Für jedes Wort  $w$  and Stelle  $i = 1, \dots, |N|$  im Dokument  $d$ :
  - 3.1 Wähle ein Thema  $z_{d,i}$  als  $Multinom(\theta_d)$
  - 3.2 Wähle ein Wort  $w_{d,i}$  als  $Multinom(\phi_{z_{d,i}})$

Für das Modell kann die Gesamtwahrscheinlichkeit berechnet werden. Diese ergibt sich aus dem Produkt aus:

- der Wahrscheinlichkeit der Topic-Word-Verteilung  $\phi$  zusammen mit der Dirichlet-Verteilung  $\beta$  für alle Topics
- der Wahrscheinlichkeit der Dokument-Topic-Verteilung  $\theta$  zusammen mit der Dirichlet-Verteilung  $\alpha$  für jedes Dokument
- der Wahrscheinlichkeit eines Topics  $z$  zusammen mit der Dokument-Topic-Verteilung  $\theta$  für alle Wörter in allen Dokumenten
- der Wahrscheinlichkeit eines Wortes  $w$  zusammen mit der Topic-Word-Verteilung  $\phi$  für alle Wörter in allen Dokumenten

$$P(w, z, \theta, \phi, \alpha, \beta) = \prod_{i=1}^K P(\phi_i, \beta) \cdot \prod_{j=1}^D P(\theta_j, \alpha) \cdot \prod_{r=1}^N P(z_{j,r} | \theta_j) \cdot P(w_{j,r} | \phi_{z_{j,r}}) \quad (2.1)$$

Abbildung 2.2: Die totale Wahrscheinlichkeit eines LDA Modells  $M$

Die Schwierigkeit des Algorithmus besteht in der Berechnung der  $\theta$ -Verteilung und entsprechenden Topics der gegebenen Dokumente für latente Variablen. Dies zeigt die Gleichung in Abbildung 2.3. Das heißt, bekannt sind Wort und Dirichlet-Paramter  $\alpha$  und  $\beta$ , während Topics und Dokument-Word-Verteilung gesucht werden. Die Gleichung ist



jedoch nur approximierbar und nicht exakt zu bestimmen. Für diesen Zweck kann Gibbs Sampling verwendet werden, wie in (Tomar, 2018) erklärt. Auch in dem Paper (Bender, 2019) wird Gibbs Sampling verwendet, um ein LDA-Modell zu trainieren. In der referenzierten Arbeit wird ein dynamisch wachsender Korpus angenommen, während in dieser Arbeit ein Korpus mit fester Größe betrachtet wird, das Prinzip bleibt jedoch gleich. Ebenfalls mit dynamisch wachsenden Korpora beschäftigt sich die Veröffentlichung (Kuhr u. a., 2020), die Aufschluss über die Funktionsweise von LDA gibt.

$$P(\theta, z | w, \alpha, \beta) = \frac{P(\theta, z, w | \alpha, \beta)}{P(w | \alpha, \beta)} \quad (2.2)$$

Abbildung 2.3: Die bedingte Wahrscheinlichkeit für das Topic und Dokument-Topic-Verteilung gegeben einem Wort und den Dirichlet-Verteilungen  $\alpha$  und  $\beta$


### Alpha und Beta

Die Dirichlet Verteilungen werden durch die beiden Parameter  $\alpha$  und  $\beta$  bestimmt. Diese formulieren die mathematische Bedeutung der beiden bereits genannten Ziele von LDA, die während der Ausführung zu verfolgen versucht werden:


1. Ein Dokument wird so wenigen Themen wie möglich zugewiesen ( $\alpha$ )
2. Jedes Thema hat so wenig relevante Wörter wie möglich ( $\beta$ )

Fall 1 kann erreicht werden, wenn alle Wörter ein Topic wären, was jedoch nicht mit Fall 2 übereinstimmen würde. Für einen erfüllten Fall 2 gibt es nicht die minimale Anzahl an Topics. Die Funktionsweise von verschiedenen  $\alpha$ -Werten zeigen folgende Abbildungen:

## 2 Grundlagen



Abbildungung 2.4: Je kleiner der  $\alpha$ -Wert wird, desto stärker dominiert ein Topic das Dokument



Abbildungung 2.5: Je größer der  $\alpha$ -Wert wird, desto gleichmäßiger sind die Topics an dem Dokument beteiligt

In der ersten Abbildung 2.4 führt ein kleiner  $\alpha = 0.01$  Wert zu einer sehr eindeutigen Dokument-Topic-Verteilung. Das erkennt man daran, dass es nur einen sehr großen blauen Kreis gibt. Jeder Kreis repräsentiert ein Topic und mit der Größe den entsprechenden Anteil am Dokument. Befinden sich zwei Kreise zum Teil auf der gleichen Position bedeutet das, dass sich die Wörter in den Topics zu einem gewissen Teil überschneiden. In Abbildung 2.4 sind bei den meisten Topics nur die Zahlen und keine Kreise zu erkennen, da die Topics einen sehr kleinen Anteil an dem Dokument haben. Dies ist durch  $\alpha$  bedingt. Bei der zweiten Abbildung 2.5 hingegen ist  $\alpha = 1$ , was eine gleichmäßigere Verteilung zur Folge hat. So sieht man, dass es viele Kreise gibt, die sich zum Teil auch überlappen. Die Größe der Kreise unterscheidet sich nicht so stark voneinander wie bei Abbildung 2.4, so-

mit sind die Topics bezüglich ihres Anteils an dem Dokument ähnlicher zueinander. Nach dem gleichen Prinzip funktioniert die Dirichlet-Verteilung der Topic-Word-Verteilung  $\beta$ . Der Trade-off zwischen den beiden Zielen ist der Grund für das Funktionieren von LDA, denn dadurch werden Gruppen mit semantisch eng miteinander verbundenen Wörtern, die oft miteinander vorkommen, gefunden.

Um LDA effizienter ausführen zu können, kann auf das Prinzip des Parallelized LDA zurückgegriffen werden. Dabei werden mehrere Kerne genutzt, um das Modell zu trainieren. Dieses Verfahren wird in (Rehurek, 2009b) genauer erklärt.

# 3

## Konzeption

Dieser Abschnitt wird die Vorgehensweise beschreiben, wie unter Nutzung der Daten des ZVO Topic-Modellierung umgesetzt wird, um Aufschluss über die Qualität der Daten zu geben. Hierfür wird die Herangehensweise dargestellt und erklärt.

### 3.1 Verfahrensweise

Bei dem ZVO sollen händisch aufgenommene Anfragen in Zukunft maschinell klassifiziert werden. Dafür wird im Rahmen des M4KK Projekts ein Kundenanfrage-Klassifikator erstellt. Für die korrekte Klassifikation ist die Qualität der vorliegenden Daten von hoher Bedeutung. Die Arbeit verfolgt das Ziel, die Qualität der Daten zu analysieren und semantische Gruppierungen zu untersuchen. Dafür wird ein LDA Modell generiert, das als Datengrundlage alle verfügbaren Daten des ZVO verwendet. Das Vorgehen ist wie folgt in Abbildung 3.1 dargestellt:

### 3 Konzeption

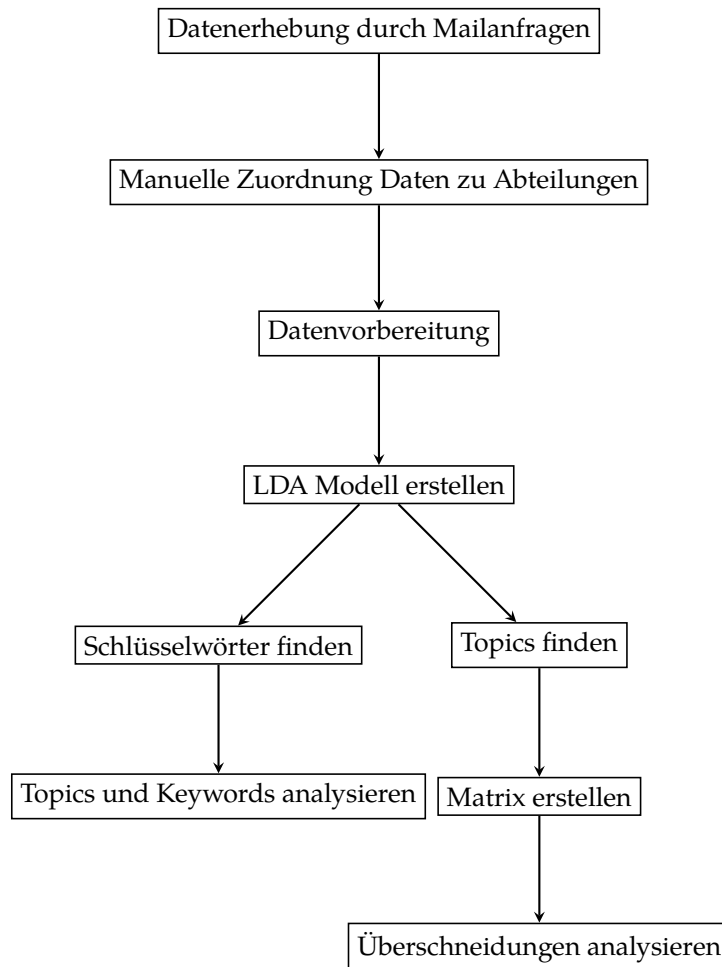


Abbildung 3.1: Prozessschritte von der Datenerhebung bis zur Analyse. Die Arbeit verfolgt zwei Ziele: Topicanalyse und Zuordnung von Topic und Label

Nach der Erhebung der Daten können die einzelnen Anfragen manuell in die vorgegebenen Abteilungsgruppen eingeteilt werden. Dort wird die Datenreinigung vorgenommen. Sind die Daten bereinigt, kann das Feature Engineering beginnen, wonach die Daten für den Computer verständlich formatiert sind. Die Erstellung des LDA Modells wird vorgenommen, sobald der Korpus erstellt ist. Die Modellerstellung ist durch den in Abbildung 3.2 gegebenen Pseudocode beschrieben.

Ist das Modell generiert und sind die Topics auslesbar, können die Daten evaluiert werden. Dazu werden zwei Ansätze verfolgt. Zum einen werden Topics und zugehörige Schlüsselwörter untersucht, um u.a. Aufschluss über mögliche Verbesserungspotentiale bei der Datenreinigung oder dem Feature Engineering festzustellen. Zum anderen werden die vom Modell erfassten Gruppen betrachtet und den manuell vorgegebenen und klassifizierten Abteilungen zugeordnet. Die folgenden Punkte beschreiben den Prozess im Detail:

---

```

data = " "
FOR d IN Anzahl Dokumente DO:
    data = data + str(d)
Teile data in einzelne items einer Liste auf
Erstelle ein Dictionary aus der Liste
Wandle ID aus Dictionary in Woerter um
Erstelle den Korpus
Erstelle das Modell
Gibt die Topic-Wort-Verteilungen für alle Topics aus

```

---

Abbildung 3.2: Pseudoalgorithmus für die Prozesskette

### Gruppen und Wörter finden

Ein LDA Modell besteht aus zwei Verteilungen, die die zugrundeliegenden Daten semantisch darstellbar machen: die Dokument-Topic-Verteilung und die Topic-Word-Verteilung. Als Ausgabe des Modells ist also zu erkennen, welche Topics die Dokumentmenge durchschnittlich hauptsächlich beschreiben und welche Wörter in den Topics jeweils dominant vorkommen. Das Modell kann Topics nicht inhaltlich benennen, sondern nur die Verteilungen darstellen. Somit ist nicht eindeutig, welches Topic welche Abteilung des ZVO darstellt. Dafür betrachtet man die Topic-Word-Verteilungen und schließt von dieser auf die Qualität der Daten. Ist über die dominanten Wörter in einem Topic zu erkennen, welche Abteilung dieses repräsentiert, scheint das Modell und die Daten gut genug zu sein, um die Daten zu klassifizieren. Sollte die Abteilung nicht an den Wörtern ablesbar sein, sind die Daten in der aktuellen Form nicht optimal für eine Klassifikation geeignet. Dabei ist auch relevant, wie oft die gleichen Wörter in den jeweiligen Topics vorkommen und ob Stop-Words Manipulation, also die Entfernung von bestimmten Wörtern aus den Dokumenten, eine Option der Qualitätssteigerung darstellt.

### Zuordnung Abteilung zu Topic

Das LDA Modell erstellt aus den Daten 18 Topics. Diese Topics sollten im optimalen Fall sehr ähnlich zu den händisch klassifizierten Abteilungen sein, wenn die vordefinierten Abteilungen eine akkurate Repräsentation der Topics in den Daten darstellen. Ist dies nicht der Fall, kann man auf eine schlechte Klassifikation schließen. Dies kann durch eine schlechte Qualität der Daten als auch durch eine ineffiziente manuelle Einteilung der Topics bedingt sein. Die Fähigkeit, Topics auf Abteilungen zu mappen, gibt Aufschluss über die Qualität der Daten. Für die Zuordnung werden zwei Matrizen verwendet: `gruppen_LABEL` und `gruppen_LDA`. Die erste sortiert alle Dokumentindizes als Listenelemente in die jeweilige Zeile der Matrix, sodass der Index eines händisch in Abteilung 3 eingeordneten Dokumentes in `gruppen_LABEL[2]` zu finden ist. Die Verzögerung ergibt sich durch den ersten Listenindex 0. Die Matrix `gruppen_LDA` beinhaltet alle Indizes der Dokumente, die vom Modell klassifiziert wurden in gleicher Struktur. Dafür wird für jedes Dokument, das den Korpus ausmacht, eine dokumenteigene Dokument-Topic-Verteilung errechnet. Das Topic, das für das Dokument am wahrscheinlichsten ist,

bestimmt, welcher Teilliste der Dokumentindex angehängt wird. Beide Matrizen verfügen nun über die Indizes der Dokumente in den jeweiligen Topics bzw. Abteilungen und können anhand der einzigartigen Indizes auf Überschneidungen geprüft werden. Die Anzahl der Überschneidungen wird in einer Matrix gespeichert, die jedes Element von `gruppen_LDA` auf jedes Element von `gruppen_LABEL` abbildet und deren Überschneidung zählt. Eine optimale Zuordnung von Topic auf Abteilung ist möglich, wenn jede Zeile ein Maximum in einer Spalte hat, die nicht auch das Maximum einer anderen Zeile enthält. Ist dies jedoch nicht der Fall, sind die Daten in der aktuellen Form nicht optimal für die Klassifizierung. Dabei ist neben der Anzahl der Überschneidungen auch die der Dokumente in dem Topic bzw. der Abteilung insgesamt als Vergleich relevant. Bei einer guten Klassifizierung ist der Unterschied zwischen den beiden klein.

# 4

## Implementierung

Dieser Abschnitt befasst sich mit der Implementierung des im Abschnitt 3 beschriebenen Konzepts. Dabei wird die Implementierung durch Python Code erklärt und die genaue Vorgehensweise dargestellt. Die Ergebnisse werden gezeigt, jedoch noch nicht analysiert. Die Implementierung von LDA in Python ist in (Rehurek, 2009a) und (Li, 2018) im Detail beschrieben.

Zur Untersuchung der Qualität der ZVO-Daten wird in dieser Arbeit die LDA-Methode verwendet. Dabei wird nur der Text als bekannt angenommen. Die Topics sind zu Beginn nicht bekannt und sollen entdeckt werden. Als grundlegendes Topic-Modellierungs-Verfahren findet es Verwendung in einem breiten Anwendungsspektrum. Durch die Bekanntheit von LDA sind bereits viele Pakete und Bibliotheken in Programmierungsumgebungen vorzufinden und einfach zu implementieren. Seit LDAs Veröffentlichung im Jahr 2000 wurde eine umfassende und detailreiche Dokumentation entwickelt, die neben vielen Forenbeiträgen die Arbeit mit LDA stark erleichtern. Bei LDA-Methoden ist die Anzahl der Topics ein individueller Input, durch den sich das Ergebnis schwerwiegend verändern kann. Die optimale Anzahl an Topics ist grundsätzlich ein elementares Problem bei Anwendungen. Im Fall des ZVO wird 18 als Anzahl der Topics gewählt, da dies die Anzahl der bereits erstellten Abteilungen ist.

Bekannte Frameworks zur Topic-Modellierung implementieren grundsätzlich ähnliche Algorithmen. Betrachtet wurden in dieser Arbeit Mallet, Gensim und Sci-kit Learn. Wichtige Schritte sind die Vorbereitung der Daten, die Implementierung, die Auswertung und die Visualisierung. Als Bibliothek wird in dieser Arbeit die Gensim Bibliothek verwendet, die für die Verarbeitung von unstrukturierten Daten und Anwendung von unüberwachten Algorithmen bekannt ist. Algorithmen, wie word2vec, LSI oder LDA entdecken automatisch Strukturen durch das Prüfen von gemeinsam auftretenden Mustern im Korpus der Trainingsdaten. Viele bekannte Algorithmen sind bereits in diesem Framework implementiert, was die Umsetzung der Topic-Modellierung vereinfacht. Gensim erlangte in der Vergangenheit Bekanntheit durch seine optimierten Implementierungen bekannter Algorithmen und der Schnelligkeit und Verlässlichkeit, mit der diese ausgeführt werden. Außerdem nutzt Gensim die Programmiersprache Python, die sich sehr gut für Probleme im Bereich des Data Science eignet.



## 4.1 Kundenanfragen des ZVO

Der ZVO erhält jährlich viele digitale Anfragen von Kunden in Form von E-Mails. Die in dieser Arbeit verwendeten Daten sind eine Sammlung, die über mehrere Jahre erweitert wurde. Jede E-Mail wird von einem Mitarbeiter des ZVO gelesen und in eine der 18 vordefinierten Abteilungen eingeteilt. Für die Zusammenarbeit mit der Universität zu Lübeck hat der ZVO 133045 unterschiedlich große Dokumente in Form einer XML Datei zur Verfügung gestellt. Die Daten wurden uni-intern zu einem Dataframe weiterverarbeitet. Auch wurden sie bereits im Vorfeld formatiert und gereinigt und sind somit nicht Teil dieser Arbeit. Das schließt unter anderem die Lemmatisierung und Entfernung von Stop-Words mit ein. Mittlerweile liegen sie in folgendem Format vor:

	filename	subject-message	Abt0	Abt1	Abt2	...	Abt16	Abt17
0	FILE0	content0	0	0	1	...	0	0
1	FILE1	content1	0	0	0	...	1	0
2	FILE2	content2	1	0	0	...	0	0
3	FILE3	content3	0	0	1	...	0	1
4	FILE4	content4	0	1	0	...	1	0
...	...	...	...	...	...	...	...	...
133044	FILE133044	content133044	0	1	0	...	0	0

Abbildung 4.1: Die Daten des ZVO liegen in einem Dataframe vor, der in subject-message die Kundenanfrage aus der Email speichert

Relevant für die Auswertung sind sowohl die subject-message, die die eigentliche Anfrage enthält, als auch die jeweilige Abteilung, der sie von dem ZVO händisch zugeordnet wurde. Die Tabelle verfügt über eine Matrix mit 18 Abteilungen, von denen pro subject-message eine oder mehrere mit einer 1 versehen ist bzw. sind. Dies beschreibt die Abteilung bzw. Abteilungen, der bzw. denen diese Anfrage manuell zugeordnet wurde. Die Daten in subject-message sind bereits bereinigt, also liegen wie in Abbildung 4.2 vor:

---

OUTPUT:

```
'wasser verbraucht amt deutschland ablesung zaehlen strom voll ort luebeck art
  straße messung verband nummer platz markieren wechsel lieferant stelle verbrauch
kunde kunden anrede mann sommer beschwerde schrift allgemein kommunikation
datenmanagement fern'
```

---

Abbildung 4.2: So könnte ein Datum des ZVO aussehen

Um die Einträge in eine computer-lesbare Form zu verwandeln, muss ein Dictionary erstellt werden, das alle Wörter auf die Anzahl ihrer Vorkommen abbildet. Dafür müssen die Wörter als alleinige Listeneinträge einlesbar sein, wie in Abbildung 4.3:

---

OUTPUT split:

```
[ 'wasser', 'verbraucht', 'amt', 'deutschland', 'ablesung', 'zaehlen', 'strom',
  'voll', 'ort', 'luebeck', 'art', 'straße', 'messung', 'verband', 'nummer',
  'platz', 'markieren', 'wechsel', 'lieferant', 'stelle', 'verbrauch', 'kunde',
  'kunden', 'anrede', 'mann', 'sommer', 'beschwerde', 'schrift', 'allgemein',
  'kommunikation', 'datenmanagement', 'fern' ]
```

---

Abbildung 4.3: Ein gesplittetes Datum vorbereitet für das Dictionary

## 4.2 Datenvorbereitung

Bevor die Topic-Modellierung auf den Daten durchgeführt werden kann, müssen die Daten einem Prozess unterzogen werden. Dieser beginnt mit der Datenakquise, also der Sammlung bestimmter relevanter Daten. Im Falle des ZVO bedeutet dies, dass es genügend Kundenanfragen gibt, die verarbeitet werden können. Wenn diese Daten vorhanden sind, werden sie auf die relevanten Wörter reduziert, aus denen eine bedeutsame Inferenz von Informationen möglich ist, sodass unter anderem die sogenannten Stop-Words, also eine Menge von bestimmten Wörtern, entfernt werden. Es gibt vordefinierte Sammlungen von Stop-Words und es können eigene definiert werden. Das Entfernen von Stop-Words verhindert, dass sich das Topic-Modell an den falschen Wörtern orientiert, die keine aussagekräftige semantische Information in sich tragen. Nachdem die Stop-Words entfernt wurden, ergeben die meisten Sätze keinen inhaltlichen Sinn mehr, wie in Abbildung 4.2 zu erkennen. Dies ist jedoch nicht relevant, da der nächste Schritt der Reinigung den Daten die Reihenfolge entzieht und das Bag of Words Modell erstellt. Dabei werden alle Wörter als eine Menge von unabhängigen Wörtern betrachtet, die sich nur durch ihre Vorkommensanzahl in dem Korpus unterscheiden. Dabei wird die Groß- und Kleinschreibung ebenfalls irrelevant, da es bei einer Menge von Wörtern ohne Reihenfolge auch keine Satzanfänge mehr gibt. Des Weiteren besteht die Möglichkeit, alle konjugierten bzw. deklinierten Formen eines Wortes zum Infinitiv bzw. Nominativ zusammenzufassen. Dies wird als Lemmatisierung bezeichnet. Wenn die Daten in der gewünschten Form vorliegen, beginnt der Schritt des Featureengineerings. Für einen Computer sind Wörter nicht so leicht zu verarbeiten wie Zahlen, weshalb in diesem Schritt eine Quantisierung der Wörter und Überführung dieser in eine zahlenbasierte Form vorgenommen wird. Dabei sind die Features in Form der Spalten des Dataframes bereits passend gegliedert. Für die Darstellung der Dokumente als Menge an Zahlenwerten wird ein Dictionary erstellt, das die Wörter wie in Abbildung 4.3 erhält und die Anzahl der Wörter ohne Duplikate in einer Liste auflistet. Diese Auflistung der Wörter zusammen mit ihrer Anzahl und laufenden Indexnummer kann als Input für ein LDA-Modell verwendet werden. Die Wörter werden intern als ID dargestellt, die für einen Menschen nicht zu verstehen ist. Aus diesem Grund wird im Algorithmus der `id2word`-Parameter eingeführt, der die Übersetzung zwischen Zahl und Datum darstellt.

### 4.3 Umsetzung Konzept

Wie in Kapitel 3 beschrieben verfolgt die Arbeit zwei Ansätze. Im Folgenden wird die Umsetzung dieser dargelegt:

#### Gruppen und Wörter finden

Alle Dokumente werden für die Erstellung eines Korpusses genutzt. Der Korpus generiert eine Topic-Verteilung für die Gesamtheit aller Dokumente. Dabei werden zuerst alle Anfragedaten in einen String zusammengefügt, der als Grundlage für das Dictionary und den Korpus dient. Um diesen in ein Dictionary, also eine nummerierte Auflistung aller Wörter und deren Anzahl, zu verwandeln, muss der String in eine Liste mit voneinander getrennten Items gesplittet werden. Hier wird ein Bag of Words Prinzip verfolgt, die Reihenfolge ist somit irrelevant für das Ergebnis des Modells. Aus der Liste wird dann das Dictionary erstellt. Durch den Aufruf des LDA-Modells wird aus dem Bag of Words mithilfe des Dictionarys eine vorgegebene Anzahl an Topics aus der Wortmenge modelliert, basierend auf häufig zusammen auftretenden Wörtern. Dadurch ergibt sich neben einer Verteilung der Topics in einem Modell die Verteilung der Wörter, die ein Topic besonders beeinflussen. Ist das Modell generiert, können die Topics ausgelesen werden. Der Programmcode für die beschriebenen Schritte ist in Abbildung 4.4 dargestellt.

---

```

INPUT:
data = ''

# Zusammenfügen aller Dokumente in einen großen String
for x in range(0,133044):
    data += df.at[x,'subject-message']

# Aufteilen des Strings in viele einzelne Wörter
list = data.split()

# Erstellen eines Dictionarys
dictionary = corpora.Dictionary([list])
id2word = dictionary.id2token

# Erstellen des Korpusses
corpus = [dictionary.doc2bow(text) for text in [list]]

# Erstellen des LDA-Modells
lda = LdaModel(corpus, num_topics=18, id2word = id2word)

#Ausgeben aller Topics inklusive Schlüsselwörtern
pprint(lda.print_topics())

```

---

Abbildung 4.4: Der Input zum Aufbau eines LDA Modells

Der Input-Code generiert aus allen Daten einen Korpus, der 18 Gruppen in den Daten findet. Jede Topic-Word-Verteilung hat die Eigenschaft, alle Wörter des Korpusses aufzulisten, auch wenn das Topic von gewissen Wörtern keinen Gebrauch macht. Die Topics, die von dem Modell generiert wurden, sind durch die zehn häufigsten Schlüsselwörter und ihren Wahrscheinlichkeiten zum Auftreten definiert. Der Output des in Abbildung 4.4 definierten Algorithmus ist in Abbildung 4.5 gelistet.

---

```

[(0,
  '0.012*"ostholstein" + 0.011*"nachricht" + 0.010*"sierksdorf" + '
  '0.009*"zweckverband" + 0.008*"betreff" + 0.008*"danken" + 0.007*"email" + '
  '0.007*"hra" + 0.007*"datum" + 0.007*"hyperlink"'),
(1,
  '0.014*"ostholstein" + 0.011*"nachricht" + 0.010*"zweckverband" + '
  '0.009*"sierksdorf" + 0.008*"sitzen" + 0.008*"danken" + 0.007*"wagrienring" '
  '+ 0.007*"lübeck" + 0.007*"betreff" + 0.006*"the"'),
(2,
  '0.014*"sierksdorf" + 0.013*"zweckverband" + 0.011*"nachricht" + '
  '0.010*"ostholstein" + 0.008*"danken" + 0.008*"betreff" + 0.007*"sitzen" + '
  '0.006*"the" + 0.006*"homepage" + 0.006*"frau"'),

```

---

---

(3,  
'0.014\*"sierksdorf" + 0.011\*"ostholstein" + 0.011\*"nachricht" + '  
'0.010\*"zweckverband" + 0.010\*"betreff" + 0.008\*"the" + 0.007\*"frau" + '  
'0.006\*"danken" + 0.006\*"denken" + 0.006\*"lübeck"''),

(4,  
'0.012\*"zweckverband" + 0.011\*"frau" + 0.011\*"sierksdorf" + '  
'0.011\*"ostholstein" + 0.009\*"nachricht" + 0.008\*"betreff" + 0.007\*"the" + '  
'0.007\*"danken" + 0.006\*"lübeck" + 0.006\*"öffentlich"''),

(5,  
'0.015\*"zweckverband" + 0.011\*"sierksdorf" + 0.011\*"ostholstein" + '  
'0.009\*"the" + 0.008\*"betreff" + 0.007\*"lübeck" + 0.007\*"danken" + '  
'0.007\*"nachricht" + 0.007\*"hyperlink" + 0.006\*"sitzen"''),

(6,  
'0.013\*"nachricht" + 0.012\*"ostholstein" + 0.012\*"zweckverband" + '  
'0.010\*"betreff" + 0.009\*"sierksdorf" + 0.007\*"danken" + 0.006\*"the" + '  
'0.006\*"lübeck" + 0.006\*"frau" + 0.005\*"hyperlink"''),

(7,  
'0.012\*"ostholstein" + 0.012\*"sierksdorf" + 0.011\*"zweckverband" + '  
'0.010\*"nachricht" + 0.008\*"danken" + 0.008\*"the" + 0.007\*"hra" + '  
'0.007\*"email" + 0.007\*"betreff" + 0.006\*"lübeck"''),

(8,  
'0.012\*"ostholstein" + 0.009\*"sierksdorf" + 0.008\*"nachricht" + '  
'0.008\*"danken" + 0.008\*"betreff" + 0.008\*"frau" + 0.008\*"zweckverband" + '  
'0.008\*"hyperlink" + 0.007\*"email" + 0.007\*"homepage"''),

(9,  
'0.013\*"sierksdorf" + 0.012\*"zweckverband" + 0.011\*"ostholstein" + '  
'0.009\*"nachricht" + 0.009\*"danken" + 0.008\*"frau" + 0.007\*"the" + '  
'0.007\*"lübeck" + 0.006\*"hyperlink" + 0.006\*"sitzen"''),

(10,  
'0.011\*"zweckverband" + 0.011\*"nachricht" + 0.010\*"sierksdorf" + '  
'0.010\*"betreff" + 0.009\*"ostholstein" + 0.009\*"lübeck" + 0.007\*"the" + '  
'0.007\*"sitzen" + 0.007\*"danken" + 0.007\*"hyperlink"''),

(11,  
'0.013\*"sierksdorf" + 0.009\*"ostholstein" + 0.009\*"zweckverband" + '  
'0.008\*"betreff" + 0.008\*"nachricht" + 0.007\*"danken" + 0.007\*"hyperlink" + '  
'0.007\*"lübeck" + 0.006\*"email" + 0.006\*"datum"''),

(12,  
'0.013\*"ostholstein" + 0.012\*"sierksdorf" + 0.009\*"nachricht" + '  
'0.009\*"zweckverband" + 0.008\*"betreff" + 0.008\*"danken" + 0.007\*"email" + '  
'0.006\*"frau" + 0.006\*"lübeck" + 0.006\*"wagrienring"''),

(13,  
'0.013\*"sierksdorf" + 0.010\*"the" + 0.010\*"zweckverband" + '  
'0.009\*"ostholstein" + 0.009\*"nachricht" + 0.008\*"danken" + 0.007\*"lübeck" + '  
'0.007\*"betreff" + 0.007\*"frau" + 0.007\*"öffentlich"''),

---

---

```

(14,
'0.012*"zweckverband" + 0.011*"danken" + 0.011*"sierksdorf" + '
'0.010*"ostholstein" + 0.010*"betreff" + 0.008*"nachricht" + '
'0.007*"hyperlink" + 0.007*"gmbh" + 0.006*"lübeck" + 0.006*"kundennummer"'),
(15,
'0.014*"ostholstein" + 0.011*"sierksdorf" + 0.008*"zweckverband" + '
'0.008*"danken" + 0.008*"frau" + 0.007*"betreff" + 0.007*"the" + '
'0.007*"nachricht" + 0.006*"amtsgericht" + 0.006*"sitzen"'),
(16,
'0.014*"zweckverband" + 0.013*"ostholstein" + 0.011*"nachricht" + '
'0.009*"danken" + 0.008*"sierksdorf" + 0.007*"hyperlink" + 0.007*"lübeck" + '
'0.006*"sitzen" + 0.006*"the" + 0.006*"betreff"'),
(17,
'0.012*"ostholstein" + 0.011*"danken" + 0.011*"sierksdorf" + 0.009*"betreff" '
'+ 0.009*"zweckverband" + 0.008*"nachricht" + 0.007*"the" + 0.007*"frau" + '
'0.006*"hyperlink" + 0.006*"sitzen"') ]

```

---

Abbildung 4.5: Die Topics und Schlüsselwörter

LDA hat erfolgreich auf allen verfügbaren Daten ein Modell erstellt, das die Daten in Topics [0, 17] eingeteilt hat. Jedes Topic hat dominante Wörter, die zusammen mit ihren jeweiligen Auftretenswahrscheinlichkeiten aufgelistet sind. Dabei sind dies nur die Wörter mit der höchsten Vorkommenswahrscheinlichkeit. Jedes Topic wird von allen verfügbaren Wörtern im Dictionary dargestellt, jeweils zu unterschiedlichen Anteilen. Die Wahrscheinlichkeiten für das Auftreten von Wörtern liegt im Intervall [1.5%, 0%]. Dabei sind viele Wörter in mehreren Topics als Schlüsselwörter zu finden.

### Zuordnung Abteilung zu Topic

Die Qualität der Daten und des Klassifikators kann alternativ über die Zuordnung der Topics zu den Abteilungen untersucht werden. Die optimalen Daten werden eine perfekte Zuordnung schaffen, ohne beim Modell eine Verwirrung festzustellen. Dafür wird in diesem Abschnitt untersucht, wie gut sich die Topics auf die Abteilungen zuordnen lassen. Der einfachste Ansatz ist, Topic  $x$  auf Abteilung  $x$  für alle  $x \in [0, 17]$  abzubilden. Dafür ist die Anzahl der Dokumente pro Topic bzw. Abteilung relevant. Dabei wird nur die Anzahl der zugeordneten Dokumente überprüft, indem für jedes von ihnen auf Basis des Korpus eine Dokument-Topic-Verteilung generiert wird. Hierbei wählt der Algorithmus für jedes Dokument das Topic aus, für das die höchste Wahrscheinlichkeit errechnet wurde. Somit kann man die Abteilungen mit den Topics vergleichen, indem man die Anzahl der zugeordneten Dokumente miteinander in Relation setzt. Um welche Dokumente es sich jedoch bei dem Vergleich jeweils tatsächlich handelt, ist zu diesem Punkt noch irrelevant. Überschneidungen werden noch nicht betrachtet. In Abbildung 4.6 ist die Anzahl der Dokumente in den Topics dargestellt:

#### 4 Implementierung

Topic	Counts LDA
T0	8605
T1	3959
T2	5974
T3	1714
T4	5823
T5	2291
T6	23558
T7	12721
T8	4207
T9	1100
T10	10021
T11	3243
T12	14556
T13	2697
T14	29456
T15	1162
T16	575
T17	1400

Abbildung 4.6: Anzahl Dokumente in den Topics

Dasselbe ergibt sich für die Abteilungen und die Anzahl der enthaltenen Dokumente. Dafür wird in dem von dem ZVO bereitgestellten Datensatz die Zuordnung für jedes Dokument abgefragt. Dadurch kann das Dokument akkurat dem Topic zugewiesen werden, wie es händisch getan wurde. Dies ist in Abbildung 4.7 zu erkennen.

#### 4 Implementierung

Abteilung	Counts Label
L0	9770
L1	21061
L2	14245
L3	235
L4	1307
L5	251
L6	4009
L7	3610
L8	9410
L9	23533
L10	20676
L11	43
L12	2866
L13	9616
L14	8144
L15	12126
L16	4748
L17	2700

Abbildung 4.7: Anzahl Dokumente in den Abteilungen

In Abbildung 4.7 sind die Abteilungen über Labels von 0 bis 17 aufgelistet. Dabei dient der Begriff Label der Adressierung einer Abteilung. So stellt Label 0 die Abteilung 0 des ZVO dar. Im Anwendungsfall steht jedes Label damit für eine reale Abteilung. Die Zuordnung der Labels zu Abteilungen ist in Tabelle 4.8 dargestellt.



## 4 Implementierung

Label	Abteilung
L0	Ablesung
L1	Allgemeiner Schriftverkehr
L2	BM-Beschwerden
L3	KA-Kommunaler Ausfall
L4	MaKo-Klärfälle
L5	ZSB-Aktionen
L6	ZSB-BAV
L7	ZSB-Zählerdatenmanagement
L8	ZSC-Forderungsmanagement
L9	ZSK-An/Abmeldungen
L10	ZSK-Bank
L11	ZSK-Interessenten
L12	ZSK-Korrekturrechnungen
L13	ZSK-Schwierige Fälle
L14	ZSK-Stammdaten/Postrückläufer
L15	ZSK-Standard Abfall
L16	ZSK-Standard Verbrauch
L17	ZSK-Widersprüche Abfall

Abbildung 4.8: Die Zuordnung von Label zu Abteilung

Die Anzahl der Dokumente eines Topics kann nun mit der einer Abteilung verglichen werden, um die grundsätzliche Kompatibilität zwischen Topics und Abteilungen prüfen zu können. Dies gibt jedoch nur eine grobe Richtung an, da die Dokumente selbst nicht geprüft werden. Das bedeutet, dass die verglichenen Anzahlen nicht prüfen, ob es sich sowohl in dem Topic, als auch in der Abteilung wirklich um das gleiche Dokument handelt. Um die Dokumente mit in den Vergleich einzubeziehen und damit die Zuordnung von Topic auf Abteilung zu verbessern, wird eine weitere Methode betrachtet. Die Zuordnung der Topics zu Abteilungen kann approximiert werden, indem gezählt wird, in wie vielen Dokumenten sich die Topics und Abteilungen jeweils überschneiden. Genau wie bei der Gruppeneinteilung wird für diese Überschneidung jedes Dokument erneut auf dem Korpus geprüft, um dessen Dokument-Topic-Verteilung zu erstellen. Die Dokumente werden anhand ihrer einzigartigen Zeilen-ID adressiert. Die IDs werden dem Topic zugeordnet, das die höchste Wahrscheinlichkeit in der Verteilung des Dokuments erreicht. Die Zuordnung findet in einer großen Liste statt, die über 18 Unterlisten verfügt, denen die IDs jeweils hinzugefügt werden. Die Überschneidungen werden in einer Matrix dargestellt, die für jedes Topic des Modells die Überschneidungen zu jeder Abteilung auflistet. Somit kann für jede Zeile die passende Zuordnung gefunden werden. Dabei stellt eine Zeile jeweils die Dokumente dar, die aufsummiert die Zahl einer Zeile in Abbildung 4.6 ergeben.

## 4 Implementierung

	L0	L1	L2	L3	L4	L5	L6	L7	L8	L9	L10	L11	L12	L13	L14	L15	L16	L17
T0	555	977	<u>2150</u>	21	66	19	211	251	910	960	902	2	210	596	302	758	318	250
T1	512	580	<u>650</u>	3	36	7	139	101	370	453	570	0	66	378	91	196	123	53
T2	508	755	263	9	67	21	254	145	282	<u>1498</u>	1207	1	119	300	479	527	177	130
T3	108	179	98	2	15	3	33	57	236	<u>432</u>	218	0	34	55	153	198	74	27
T4	493	867	442	5	63	8	134	180	451	<u>1111</u>	1033	8	73	348	446	489	191	89
T5	91	467	98	5	25	2	60	75	162	<u>480</u>	309	1	55	127	169	351	113	47
T6	1263	3993	1738	28	127	48	811	587	1384	4139	<u>4730</u>	6	573	2096	1620	2080	680	495
T7	<u>3376</u>	1298	870	17	524	16	221	338	662	1904	1740	9	185	381	664	891	537	133
T8	310	585	216	10	27	5	67	114	203	771	<u>1013</u>	0	81	323	264	440	205	73
T9	58	126	47	0	3	1	17	16	131	174	<u>400</u>	0	15	55	63	69	59	17
T10	286	<u>1610</u>	1733	12	51	27	284	299	858	1567	1331	4	239	893	674	673	304	248
T11	194	409	377	8	27	3	88	122	180	<u>678</u>	470	0	80	173	167	395	142	118
T12	486	2355	2495	16	80	24	564	327	1005	<u>2672</u>	1513	3	311	1254	886	1377	579	327
T13	151	393	198	5	23	4	64	83	160	414	<u>639</u>	1	68	192	123	275	151	68
T14	1008	6084	2681	86	153	61	990	820	2223	<u>5730</u>	3832	8	701	2327	1860	3093	993	552
T15	270	95	36	3	10	1	29	32	46	228	<u>284</u>	0	19	31	61	81	23	21
T16	81	82	25	1	3	0	18	38	27	<u>105</u>	90	0	14	29	37	76	24	15
T17	20	206	128	4	7	1	25	25	120	<u>217</u>	395	0	23	58	85	157	55	37

Tabelle 4.9: Anzahl der Überschneidungen zwischen LDA Topics (vert.) und ZVO Labels (horiz.) mit den maximalen Werten pro Zeile in **fett** markiert

Diese Matrix bildet die Überschneidungen aller 133045 Dokumenten ab. Dabei sind die 18 LDA Topics auf der vertikalen Achse und die 18 Label Abteilungen auf der horizontalen Achse aufgetragen. Bezüglich der Zuordnung ist der einfachste Ansatz, jeder Zeile (also LDA Topic) die Spalte (also Label Abteilung) mit der maximalen Überschneidung zuzuordnen. Dabei ist das Ziel, die Anzahl der Gesamtüberschneidungen zu maximieren. Ein weiteres Experiment ist, die Matrix mit durchschnittlichen Werten zu verwenden. Dabei wird somit nicht mehr die absolute maximale Überschneidung in jeder Zeile als Zuordnung gewählt, sondern die maximale Überschneidung in Bezug auf die Abteilungsgröße.

# 5

## Experimentelle Evaluation und Analyse

Die Implementierung des LDA Modells wurde in Kapitel 4 vorgenommen. In diesem Abschnitt werden die Ausgaben analysiert und aus verschiedenen Perspektiven auf Erkenntnisse geprüft. Wie in Abschnitt 3 und 4 wird auch dieser Abschnitt in zwei Teilbereiche dieser Arbeit unterteilt.

### Gruppen und Wörter finden

Das LDA Modell hat 18 Gruppen aus den Daten generiert und diese mit einer Verteilung von Schlüsselwörtern beschrieben. Als Anwendungsziel in Bezug auf den ZVO sollen die Topics des Modells in Zukunft die Abteilungen darstellen. Betrachtet man dafür die Wörter der Topics, um die Topics semantisch den Abteilungen zuzuordnen, wird dies nicht gelingen. Das liegt daran, dass sich die dominanten Wörter in den Topics zu stark überschneiden. Zum Beispiel gehört „ostholstein“ in allen Topics zu den häufigsten 5 Wörtern. In der folgenden Darstellung sind die häufigsten 5 Wörter aufgelistet und mit den 18 Topics auf Vorkommen geprüft:




Abbildung 5.1: Topicabdeckung der häufigsten 5 Wörter aller Topics

In Abbildung 5.1 sind die häufigsten 5 Wörter aller Topics auf der Y-Achse aufgelistet. Die X-Achse beschreibt die Anzahl der Topics, die das bestimmte Wort als eines der häufigsten 5 besitzen. Hätten alle 18 Topics Schlüsselwörter, die das Topic eindeutig beschreiben, würden sich 90 verschiedene Wörter auf der Y-Achse ergeben. Hier sind jedoch nur 9 Wörter aufgezählt, deren Anzahl sich auf 90 addiert. Die Topics teilen sich also bezüglich 90 möglichen Schlüsselwörtern nur 9 Wörter. Das bedeutet, dass sich die Topics semantisch sehr schwach bis gar nicht voneinander unterscheiden lassen. Dies ist auf die Qualität der Daten und deren Wörter zurückzuführen. Die Topics lassen sich nicht stark genug voneinander abgrenzen, wenn in jedem Topic dieselben Wörter zu einem hohen Anteil vorkommen. Jedoch kann die Qualität der Daten und damit die des Klassifikators erhöht werden, indem die Stop-Words erweitert werden. Wenn man beispielsweise das Wort „ostholstein“ betrachtet, ist dies nicht aussagekräftig für die Abteilung, da sich alle Abteilungen in Ostholstein befinden. Die Wahl der zu ergänzenden Stop-Words hängt also auch von der semantischen Bedeutung des Wortes ab. Dazu muss auf die Anzahl der Wörter insgesamt geachtet werden und die stark vertretenen Wörter dieser Art entfernt werden. Zuletzt ist bedeutend, wie stark die semantische Bedeutung des jeweiligen Wortes für die bestimmte Abteilung ist. Ein Wort, das eine ganz bestimmte Abteilung beschreibt, wie „ablesen“ die Abteilung „Ablesung“, darf natürlich nicht entfernt werden. Dies muss jedoch analog entschieden werden.

### Zuordnung Abteilung zu Topic

Wie in der Konzeption beschrieben ist, der einfachste Ansatz, um die Topics als Abteilungen zu interpretieren, ihnen der Reihenfolge nach die Abteilungen zuzuordnen. Also

würde Topic 0 Abteilung 0 zugeteilt bekommen.




Abbildung 5.2: Vergleich der Anzahl an Dokumenten pro Topic bzw. Abteilung

Das Säulendiagramm in Abbildung 5.2 bildet jeweils für alle  $x \in [0, 17]$  Abteilung  $x$  auf Topic  $x$  ab und stellt die Anzahl der Dokumente in diesen Topics bzw. Abteilungen gegenüber. Dies zeigt, dass die Topics nicht optimal auf die Abteilungen abgebildet sind. Die Anzahl der enthaltenen Dokumente sollte ähnlicher sein. Betrachtet man zum Beispiel Topic 14, kann diese nicht Abteilung 14 darstellen, da es sich um einen Unterschied von 21312 Dokumenten, also 72%, handelt.

Die Abbildung 5.2 zeigt, dass die Topics unabhängig von ihrem Index jeder Abteilung zugeordnet werden könnten. Um die korrekte Zuordnung zu finden, müssen alternative Ansätze gefunden werden. In den Abbildungen 4.6 und 4.7 ist die Anzahl der Dokumente in den jeweiligen Topics und Abteilungen aufgelistet. Um eine bessere Übersicht über die Daten zu bekommen, sind die Listen in den folgenden Abbildungen nach der Größe sortiert und mit einem weiteren Parameter dargestellt, der als Vergleichswert dienen soll. Dieser Parameter stellt den prozentualen Anteil der Topics im Korpus dar:

## 5 Experimentelle Evaluation und Analyse

Topics	Counts LDA	Anteil[%]
14	29456	22.13
6	23558	17.7
12	14556	10.94
7	12721	9.56
10	10021	7.53
0	8605	6.47
2	5974	4.49
4	5823	4.38
8	4207	3.16
1	3959	2.98
11	3243	2.44
13	2697	2.03
5	2291	1.72
3	1714	1.29
17	1400	1.05
15	1162	0.87
9	1100	0.83
16	575	0.43

Abbildung 5.3: Anzahl Dokumente in Topics mit relativem Anteil

Abteilung	Counts Label	Anteil[%]
9	23533	15.86
1	21061	14.20
10	20676	13.94
2	14245	9.6
15	12126	8.17
0	9770	6.59
13	9616	6.48
8	9410	6.34
14	8144	5.49
16	4748	3.20
6	4009	2.7
7	3610	2.43
12	2866	1.93
17	2700	1.82
4	1307	0.88
5	251	0.17
3	235	0.16
11	43	0.03

Abbildung 5.4: Anzahl Dokumente in Abteilungen mit relativem Anteil

Nun wird durch die Darstellung deutlich, dass sich nicht alle Topics eindeutig einer Abteilung zuordnen lassen. Dafür sind die Häufigkeiten in Abbildung 5.3 und Abbil-

dung 5.4 zu unterschiedlich. Das Ergebnis zeigt, dass die Topic-Verteilung bei LDA das 14. Thema stärker erkennt als der ZVO die Abteilung mit den meisten zugeordneten Dokumenten. Diese unterscheiden sich durch 5923 Dokumente. Dies ist auch zu erkennen, wenn man sich die prozentualen Anteile von den Topics und Abteilungen anschaut. Das größte Topic unterscheidet sich von der größten Abteilung in über 6%. Die Betrachtung der unterschiedlichen Anteile dient somit nicht gut als Zuordnungsmethode, kann jedoch Aufschluss darüber geben, dass die Daten von dem ZVO gleichmäßiger zugeteilt wurden als sie von dem Topic-Modell erkannt werden. Dies bedeutet, dass die Wörter in den Dokumenten in ihrer Bedeutung und syntaktischen Umgebung zu ähnlich sind, um sich optimal in die vom ZVO vorgegebenen Abteilungen einteilen zu lassen. Dies könnte auch an bestimmten Wörtern liegen, die in vielen Abteilungen vorkommen, wie zum Beispiel „ostholstein“ oder „zweckverband“. Die Wörter können dafür sorgen, dass Dokumente in das gleiche Topic sortiert werden, die sich eigentlich durch andere Wörter semantisch stärker voneinander unterscheiden und manuell anderen Abteilungen untergeordnet wurden.

Die reine Anzahl der Dokumente ist nicht aussagekräftig genug, um eine Qualität der Zuordnung umfassend zu untersuchen. Dafür werden die Überschneidungen zwischen Topic und Abteilung betrachtet. Für die Zuordnung der Topics auf Abteilungen wurde in Abschnitt 4 in Tabelle 4.9 eine Matrix erstellt, die alle Überschneidungen gezählt hat. Diese wurden dann für alle Topics und Abteilungen in der Matrix als absolute Werte aufgetragen. Abbildung 5.5 stellt die Ergebnisse der Matrix in einem Graphen dar, auf dem die X-Achse die Labels, also Abteilungen, aufträgt und die Y-Achse für die Anzahl der überschneidenden Dokumente steht. Wie viele Dokumente sich in jedem Topic und Abteilung überschneiden, ist durch die 18 Graphen dargestellt, die jeweils den Wert in einer Funktion aufgetragen haben. Aus Abbildung 5.5 ist ein globaler Trend zu erkennen, der bei den Abteilungen 1, 2 und 9, 10 sehr viele Überschneidungen aufweist.

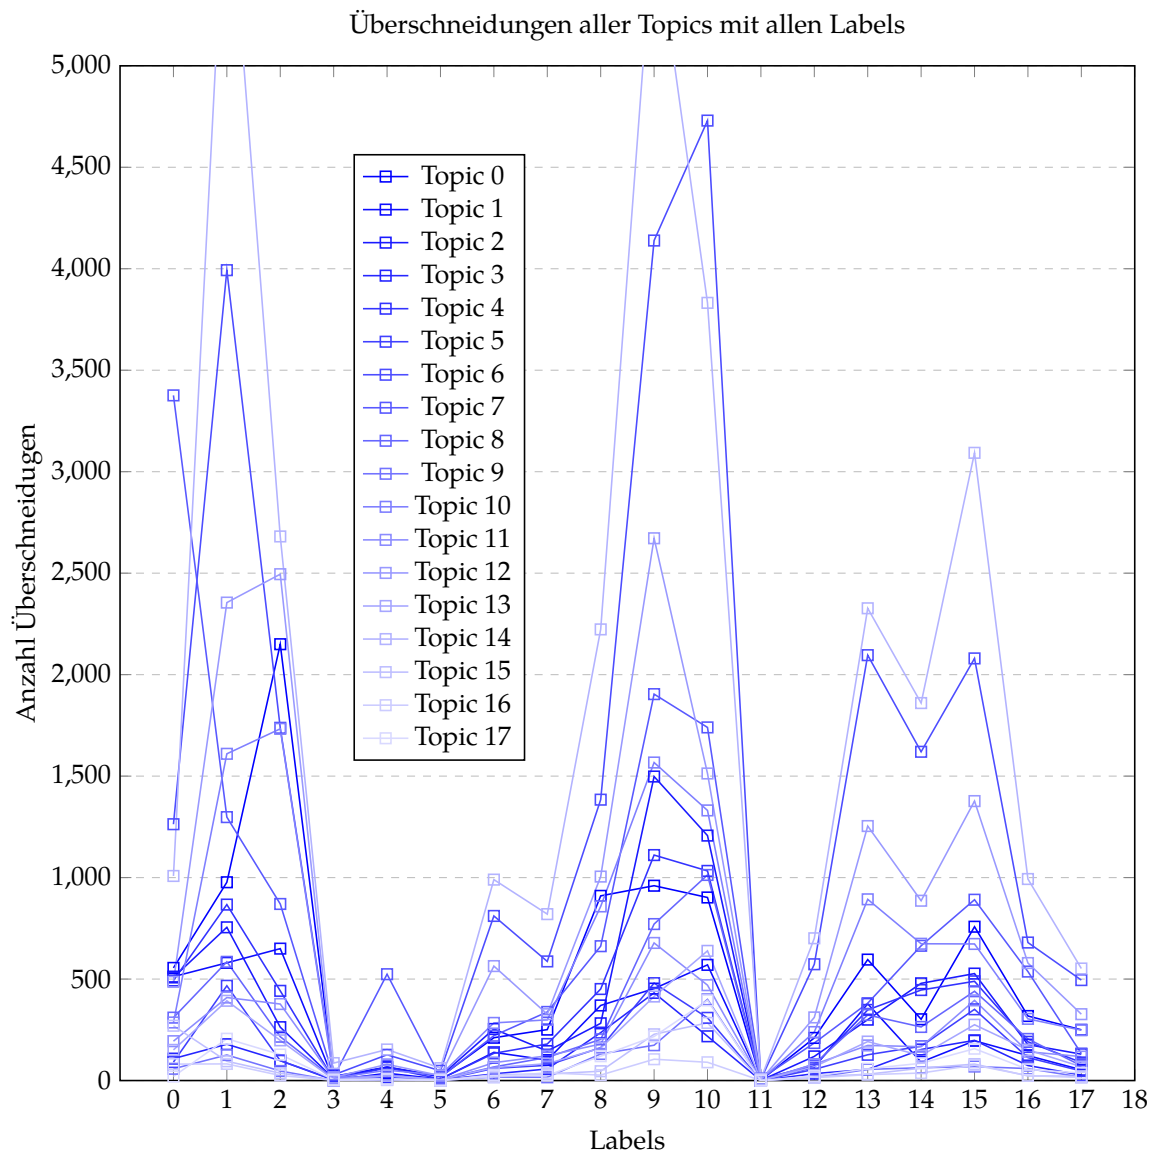


Abbildung 5.5: Alternative Darstellung der Matrix 4.9

Die Erkenntnis kann auf die hohe Anzahl der Dokumente in diesen Abteilungen zurückgeführt werden. Gleichzeitig haben Abteilungen wie *L5* oder *L3* sehr wenig Dokumente von dem ZVO zugewiesen bekommen und stellen somit keine Lösung einer möglichen Zuordnung dar. Eine alternative Erklärung könnte sein, dass die Dokumente in den Abteilungen ein sehr breites semantisches Spektrum abdecken, womit sich viele Topics identifizieren können. Wählt man für jedes Topic die Abteilung mit der maximalen Überschneidung, erhält man die Liste in Abbildung 5.6, die jedem Index, der die Topics repräsentiert, die Abteilungen als Werte zuordnet.



---


$$\text{maxmatrix} = [2, 2, 9, 9, 9, 9, 9, 10, 0, 10, 10, 1, 9, 9, 10, 9, 10, 9, 9]$$


---

Abbildung 5.6: Liste der zugeordneten Topics und Abteilungen bei maximaler Überschneidung pro Topic

Für diese Zuordnung prüft man nun die Anzahl der Dokumente in den jeweils gewählten Topics bzw. Abteilungen. Dabei ist die reine Schnittmenge nicht der alleinige Parameter. Dafür werden die Anteile aus Abbildung 4.6 und Abbildung 4.7 zum Vergleich herangezogen. Eine Zuordnung ist nur dann gut, wenn die Überschneidungsmenge möglichst nah an der Gesamtmenge der zugeordneten Dokumente in den Topics bzw. Abteilung ist. Eine vergleichsmäßig hohe Schnittmenge bedeutet nicht automatisch eine korrekte Zuteilung, wenn der Abteilung zum Beispiel manuell deutlich mehr Daten zugeordnet wurden.

Wie zu erkennen ist, sind nur die Zahlen 0, 1, 2, 9, 10 in der Liste vertreten. Eine optimale Zuordnung wäre jedoch erst erreicht, wenn alle Zahlen von 1 bis 18 ohne Duplikate in der Liste in einer beliebigen Reihenfolge vorkommen. Dies liegt daran, dass ein Topic nur genau eine Abteilung darstellen darf. In der Liste wird jedoch deutlich, dass viele Themen des LDA-Modells mit dem neunten Thema des ZVO kompatibel wären. Dabei werden 9/18 Topics Abteilung 9, 1/18 Topic Abteilung 1, 5/18 Topics Abteilung 10 und 2/18 Topics Abteilung 2 zugeordnet. Hier fällt auf, dass diesen Abteilungen die meisten Dokumente von dem ZVO händisch zugeordnet wurden. Somit können sie sich auch mit vielen Dokumenten aus den LDA-Topics überschneiden. Dies lässt zusätzlich vermuten, dass zum Beispiel die Abteilung 9, die laut Abbildung 4.7 die meisten Dokumente enthält, ein zu breites inhaltliches Spektrum abdeckt und in noch weitere Unterthemen unterteilt werden könnte. Dies wird dadurch begründet, dass das Topic-Modell viele der Dokumente aus Abteilung 9 in verschiedene Topics eingeteilt hat.




Abbildung 5.7: Die Abbildung 5.6 zeigt die gewählten Zuordnungen. Diese werden in dieser Abbildung mit den absoluten Dokumentmengen der Topics bzw. Abteilungen verglichen

Die Abbildung 5.7 stellt die Überschneidungen mit der Menge der Dokumente in den Topics und Abteilungen gegenüber. Dabei zeigen die orangefarbenen Balken die Anzahl der Dokumente, die in den 18 Topics nach der Zuordnung des LDA-Modells enthalten sind. Basierend auf der Zuordnung in Abbildung 5.6 wurde jedem Topic eine Abteilung zugeordnet. Dies ist an den blauen Labels über den Balken zu erkennen. Die Anzahl der enthaltenen Dokumente in der jeweiligen Abteilung wird in Form der blauen Balken dargestellt. Die roten Balken stellen zusammen mit der roten Funktion die Anzahl der Überschneidungen zwischen Topic und Abteilung und dessen Verlauf dar. Es ist zu erkennen, dass die roten Säulen im Vergleich zu den Topics und Abteilungen sehr klein ausfallen. Das bedeutet, dass die Anzahl der in Topics und Abteilungen enthaltenen Dokumente

deutlich größer ist als die Anzahl der Überschneidungen zwischen ihnen. Somit verliert das Maß der Überschneidung an Bedeutung und zeigt die Inkompatibilität deutlich. Die Erkenntnis aus dieser Abbildung ist demnach, dass die maximale Überschneidung nicht die höchste Ähnlichkeit zwischen Topics und Abteilungen darstellt.

Die Zuteilung anhand der maximalen absoluten Überschneidungen ist dazu nicht injektiv. Für die Verarbeitung der Daten ist die injektive Zuordnung jedoch fundamental wichtig, aber schwierig zu erreichen. Für die Beurteilung der Matrix führen wir einen weiteren Parameter ein: die durchschnittliche Überschneidung. Dadurch kann die Kompatibilität der Abteilungen in Bezug auf das Matching mit Topics besser analysiert werden. Vor allem bei Abteilungen, die eine sehr unausgeglichene Überschneidungsmenge haben, da sie deutlich mehr Dokumente als andere enthalten, bietet der Durchschnitt eine alternative Sichtweise. Für die durchschnittliche Überschneidung wird zuerst die Summe aller Dokumente einer Abteilung errechnet, indem alle Werte einer Spalte addiert werden. Daraufhin entsteht eine neue Matrix, in der jeder Wert jeweils durch die Summe seiner Spalte dividiert wird. Dabei wird die Anzahl an Dokumenten in jeder Abteilung irrelevant für das Endergebnis. Somit beschreibt jeder Wert, wie groß der Anteil der Überschneidungen bezogen auf die Anzahl aller Dokumente in der Abteilung ist in %:

	L0	L1	L2	L3	L4	L5	L6	L7	L8	L9	L10	L11	L12	L13	L14	L15	L16	L17
T0	5.7	4.6	<u>15.1</u>	8.9	5.1	7.6	5.3	6.9	9.7	4.1	4.4	4.7	7.3	6.2	3.7	6.3	6.7	9.3
T1	<u>5.2</u>	2.8	4.6	1.3	2.78	2.8	3.5	2.8	3.9	1.9	2.8	0	2.3	3.9	1.1	1.6	2.6	2
T2	5.2	3.6	1.9	3.8	5.1	<u>8.4</u>	6.3	4	3	6.4	5.8	2.3	4.2	3.1	5.9	4.4	3.7	4.8
T3	1.1	0.9	0.7	0.9	1.2	1.2	0.8	1.6	<u>2.5</u>	1.8	1.1	0	1.1	0.6	1.9	1.6	1.6	1
T4	5.1	4.1	3.1	2.1	4.8	3.2	3.3	5	4.8	4.7	5	<u>18.6</u>	2.5	3.6	5.5	4	4	3.3
T5	0.9	2.2	0.7	2.1	1.9	0.8	1.5	2.1	1.7	2	1.5	2.3	1.9	1.3	2.08	<u>2.9</u>	2.4	1.7
T6	12.9	19	12.2	11.9	9.7	19.1	20.2	16.3	14.7	17.6	<u>22.9</u>	14	20	21.8	19.9	17.2	14.3	18.3
T7	34.6	6.2	6.1	7.2	<u>40.1</u>	6.4	5.5	9.4	7	8.1	8.4	20.9	6.5	4	8.2	7.4	11.3	4.9
T8	3.2	2.8	1.5	4.3	2.1	2	1.67	3.16	2.2	3.3	<u>4.9</u>	0	2.8	3.4	3.2	3.6	4.3	2.7
T9	0.6	0.6	0.3	0	0.2	0.4	0.4	0.4	1.4	0.7	<u>1.9</u>	0	0.5	0.6	0.8	0.6	1.2	0.6
T10	2.9	7.6	12.2	5.1	3.9	<u>10.8</u>	7.1	8.3	9.1	6.7	6.4	9.3	8.3	9.3	8.3	5.6	6.4	9.2
T11	2	1.9	2.7	3.4	2.1	1.2	2.2	3.4	1.9	2.3	2.3	0	2.8	1.8	2.1	3.3	3	<u>4.4</u>
T12	5	11.2	<u>17.5</u>	6.8	6.1	9.6	14.1	9.1	10.7	11.4	7.3	7	10.9	13	10.9	11.4	12.2	12.1
T13	1.6	1.9	1.4	2.1	1.8	1.6	1.6	2.3	1.7	1.8	3.1	2.3	2.4	2	1.5	2.3	<u>3.2</u>	2.5
T14	10.3	28.9	18.8	<u>36.6</u>	11.7	24.3	24.7	22.7	23.6	24.4	18.5	18.6	24.5	24.2	22.8	25.5	20.9	20.4
T15	<u>2.8</u>	0.5	0.3	1.3	0.8	0.4	0.7	0.9	0.5	1	1.4	0	0.7	0.3	0.8	0.7	0.5	0.8
T16	0.8	0.4	0.2	0.4	0.2	0	0.5	<u>1.1</u>	0.3	0.5	0.4	0	0.5	0.3	0.5	0.6	0.5	0.6
T17	0.2	1	0.9	1.7	0.5	0.4	0.6	0.7	1.3	0.9	<u>1.9</u>	0	0.8	0.6	1	1.3	1.2	1.4

Tabelle 5.8: Durchschnittliche Überschneidungen aller Topics mit Labels

Wählt man aus jeder Zeile das maximale Element aus und notiert die assoziierten Abteilungen in einer Liste, dann ergibt sich das folgende Ergebnis. Der Unterschied bei der Darstellung ist nun, dass die Zahlen pro Zeile nicht mehr als absolutes Maß betrachtet werden, sondern als relative Häufigkeit in der jeweiligen Abteilung. Somit macht es keinen Unterschied, dass die Abteilungen verschieden viele Dokumente vom ZVO zugeordnet bekommen haben.

---

```
average_row = [2,0,5,8,11,15,10,4,10,10,2,17,2,16,3,0,7,10]
```

---

Abbildung 5.9: Zuordnung zwischen LDA und Label

Man erkennt eine leichte Verbesserung zu Tabelle 4.9, da in der Zuteilung mehr Abteilungen zugeordnet wurden. Insgesamt sind jedoch immer noch nur 12/18 in der Liste vertreten. Wie bei der ersten Liste, bei der 0, 1, 2, 9, 10 mehrfach zugewiesen wurden, sind hier 2 und 10 drei mal zugewiesen und 0 zwei mal. Somit unterstreicht das Ergebnis die Problematik der Zuteilung des ZVO in Bezug auf diese Abteilungen. Die Daten sind somit nicht für die Nutzung in der Topic-Modellierung geeignet.

Das erste Experiment zeigt, dass die Daten in den Abteilungen des ZVO zu ähnlich sind. Die Schlüsselwörter, die die Topics am stärksten beschreiben, sind sehr ähnlich, wodurch eine eindeutige Einteilung der Daten in Abteilungen erschwert wird. Um die Daten in 18 Abteilungen eindeutig einteilen zu können, müssen für das LDA-Modell in den Daten der Abteilungen eindeutige Muster zu erkennen sein. Dies ist mit so einer hohen Ähnlichkeit nicht möglich.

Bei dem zweiten Experiment führt eine sehr schwierige und unsichere Zuordnung der Topics und Abteilungen zu dem Ergebnis, dass in den Daten keine Muster zu erkennen sind, die eindeutig auf eine der vorgegebenen Abteilungen hindeuten. Dies ist daran zu erkennen, dass die Zuordnungen nicht injektiv sind und die Überschneidungen zwischen Abteilungen und Topics sehr klein und aussageschwach sind. Die Überschneidungsmengen sind dazu deutlich kleiner als die Anzahl der in Abteilung bzw. Topic enthaltenen Dokumente.

# 6

## Zusammenfassung und Ausblick

Topic-Modellierung wird vielseitig eingesetzt, um aus großen Datenmengen Themen zu extrahieren. Wie in (Blei, 2012) gezeigt, wird das Prinzip der Topic-Modellierung in der Zukunft eine große Rolle in der Textverarbeitung spielen. Die Daten stellen in dieser Arbeit die Kundenanfragen des ZVO dar. Dieser erhält jährlich große Datenmengen an Kundenanfragen, die händisch von Mitarbeitern gelesen und klassifiziert werden. Aktuell wird an einem Klassifikator gearbeitet, der die Anfragen in Zukunft selbstständig klassifizieren soll. Dafür wurde in dieser Arbeit das Ziel verfolgt, die Qualität dieses Klassifikators vorherzusagen, indem die Qualität der Daten analysiert und die Gruppierung der Abteilungen des ZVO untersucht wurden. Für diese Anwendung wurde Topic-Modellierung verwendet, da es erlaubt, Daten nicht nur einer, sondern mehreren Klassen zuzuordnen. Dies stellt den Unterschied zwischen Topic-Modellierung und Clustering dar und bietet sich für die Anwendung auf den ZVO-Daten an. Als Methode der Topic-Modellierung wurde Latent Dirichlet Allocation (LDA) verwendet - eine der weltweit am weitest verbreiteten Methoden. Diese wurde in der Bibliothek Gensim umgesetzt, die die Anwendung der Methode durch viele effizient vorimplementierte Algorithmen erleichterte. Die Daten durchliefen nach der Akquise einen Datenvorbereitungsprozess, in dem sie gereinigt wurden. Dies umfasste die Formatierung, Ausdünnung durch die Entfernung von Stop-Words, Lemmatisierung und Erstellung der Features. Auf Basis der vorverarbeiteten Daten konnte ein Topic-Modell generiert werden. Dieses hat 18 Topics mit Schlüsselwörtern erstellt, die zu unterschiedlichem Anteil in dem Korpus vorkommen. Um die Qualität der Daten zu analysieren, wurden die erhaltenen Topics und deren Schlüsselwörter analysiert. Dabei wurde die Erkenntnis gewonnen, dass die häufigsten 5 Schlüsselwörter der Topics nur aus 9 verschiedenen Wörtern bestehen. In dem Korpus wurde demnach von dem LDA-Modell kein Muster gefunden, das die Topics semantisch eindeutig unterteilt, da sie sich in den Schlüsselwörtern sehr ähnlich waren. Als Folgerung heißt dies, dass die Daten eine zu schlechte Qualität aufweisen, um sie von einem Topic-Modellierungs-Algorithmus einteilen lassen zu können. In der Arbeit wurde noch ein weiteres Experiment durchgeführt, das die Erkenntnis bestärkte. Jenes Experiment bestand aus dem Versuch, die erhaltenen Topics vorgefertigten Abteilungen zuzuordnen. Dafür wurde eine Matrix aufgebaut, die alle Überschneidungen der Topics und Abteilungen aufzeichnet. Durch diese Aufzeichnung wurde deutlich, dass es Abteilungen unter den ZVO-Gruppierungen gibt, die deutlich mehr Daten beinhalten als

andere. Diese Ungleichheit führt wiederum dazu, dass manche Abteilungen zu wenig Daten besitzen, als dass ein Machine-Learning-Algorithmus eigene Muster in ihnen erkennen kann. Die ungleichmäßige Verteilung wurde in einer Darstellung deutlich, die die Anzahl der zugeordneten Dokumente abbildet. Zusätzlich stellte eine andere Darstellung die Überschneidungen den absoluten Anzahlen der Dokumente in den Topics und Abteilungen gegenüber. Die Erkenntnis aus diesem Graphen war, dass die Überschneidungen nur einen kleinen Teil der Dokumente in Abteilungen bzw. Topics ausmachten und somit sehr wenig über die Semantik in den Topics und zugeordneten Abteilungen aussagen konnten. Dazu wurde festgestellt, dass die Abteilungen, bei denen die Überschneidungen größer waren, auch sehr viel mehr Daten überhaupt besaßen. Die Quote der durchschnittlichen Überschneidung war somit immer noch sehr unbefriedigend. Das Ergebnis des zweiten Experiments verstärkt somit die erste Hauptidee, dass die Daten sich in ihrer aktuellen Form aufgrund von ungleicher Verteilung und zu ähnlichen Wörtern in händisch eingeteilten Abteilungen nicht für eine automatische Klassifikation durch Topic-Modellierung eignen.

## Literatur

Ahuja, A., Wei, W. und Carley, K. (2015). *Topic modeling in large scale social network data*. Techn. Ber. Institute of Software Research, School of Computer Science, Pittsburgh.

AlSumait, L., Barbara, D., Gentle, J. und Domeniconi, C. (2009). *Topic Significance Ranking of LDA Generative Models*. Techn. Ber. Department of Computer Science, George Mason University.

Anupriya, P. und Karpagavalli, S. (2015). *LDA based topic modeling of journal abstracts*. Techn. Ber. International Conference on Advanced Computing and Communication Systems. IEEE.

Bender, M. (2019). *Betrachtung eines statistischen Topic-Modells zur Repräsentation wechselnder Dokumente*. Bachelorarbeit.

Blei, D.M. (2012). Probabilistic Topic Models. *Communication of the ACM*, 77–84.

Blei, D.M., Ng, A. und Jordan, M.I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 993–1022.

Chemudugunta, C. (2010). *Text Mining with Probabilistic Topic Models: Applications in Information Retrieval and Concept Modeling*. LAP Lambert Academic Publishing.

Doll, T. (2018). *LDA Topic Modeling An Explanation*. Towards Data Science Inc. <https://towardsdatascience.com/lda-topic-modeling-an-explanation-e184c90aadcd>. (Besucht am 21.09.2021).

Groppe, J. *KI in der Kundenkommunikation*.

Hofmann, T. (1975). Probabilistic Latent Semantic Analysis. *EECS Department Computer Science Division*, 289–294.

Jelodar, H., Wang, Y. und Yuan, C. (2019). Latent Dirichlet allocation (LDA) and topic modeling: models, applications, a survey. *Springer*, 2–32.

Kuhr, F., Bender, M., Braun, T. und Möller, R. (2020). Maintaining Topic Models for Growing Corpora. In *Proceedings of the 14th IEEE International Conference on Semantic Computing (ICSC-20)*, IEEE, S. 451–458. doi: <https://doi.org/10.1109/ICSC.2020.00017>.

Li, S. (2018). *Topic Modeling and Latent Dirichlet Allocation(LDA) in Python*. Towards Data Science Inc. <https://towardsdatascience.com/topic-modeling-and-latent-dirichlet-allocation-in-python-9bf156893c24>. (Besucht am 20. 09. 2021).

Mohammed, S. und Al-augby, S. (2019). *LSA & LDA Topic Modeling Classification: Comparison study on E-books*. Techn. Ber. Department of Computer Science, Faculty of Computer Science und Mathamatics, University of Kufa, Iraq.

Rehurek, R. (2009a). *LDA Model*. Gensim. <https://radimrehurek.com/gensim/models/ldamodel.html>. (Besucht am 21. 09. 2021).

Rehurek, R. (2009b). *Parallelized Latent Dirichlet Allocation*. Gensim. <https://radimrehurek.com/gensim/models/ldamulticore.htm>. (Besucht am 21. 09. 2021).

Řehůřek, R. und Sojka, P. (Mai 2010). Software Framework for Topic Modeling with Large Corpora. English. In Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks, <http://is.muni.cz/publication/884893/en>. Valletta, Malta: ELRA, S. 45–50.

Tenzer, F. (2020). *Prognose zum Volumen der jährlich generierten digitalen Datenmenge weltweit in den Jahren 2018 und 2025*.

Tomar, A. (2018). *Topic modeling using Latent Dirichlet Allocation (LDA) and Gibbs Sampling explained*. Analytics Vidhya. <https://medium.com/analytics-vidhya/topic-modeling-using-lda-and-gibbs-sampling-explained-49d49b3d1045>. (Besucht am 21. 09. 2021).

Zamani, M., Schwartz, H.A. und Eichstaedt, J. (2020). Understanding Weekly COVID-19 Concerns through Dynamic Content-Specific LDA Topic Modeling. Proc Conf Empir Methods Nat Lang Process, 1–6.