



UNIVERSITÄT ZU LÜBECK
INSTITUT FÜR
THEORETISCHE INFORMATIK

Vorlage für die \LaTeX -Klasse »uzl-thesis« zur Nutzung bei Bachelor- und Masterarbeiten an der Universität zu Lübeck

*Template for the \LaTeX Class “uzl-thesis” for Bachelor’s and Master’s Theses
Written at the University of Lübeck*

Bachelorarbeit

verfasst am

Institut für Theoretische Informatik

im Rahmen des Studiengangs

Informatik

der Universität zu Lübeck

vorgelegt von

Leonard

ausgegeben und betreut von

X

mit Unterstützung von

Harry Hilfreich

Lübeck, den 1. Januar 2021

Eidesstattliche Erklärung

Ich erkläre hiermit an Eides statt, dass ich diese Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Leonard

Zusammenfassung

Es ist nicht leicht, eine Abschlussarbeit so zu schreiben, dass sie nicht nur inhaltlich gut ist, sondern es auch eine Freude ist, sie zu lesen. Diese Freude ist aber wichtig: Wenn die Person, die die Arbeit benoten soll, wenig Gefallen am Lesen der Arbeit findet, so wird sie auch wenig Gefallen an einer guten Note finden. Glücklicherweise gibt es einige Kniffe, gut lesbare Arbeiten zu schreiben. Am wichtigsten ist zweifelsohne, dass die Arbeit in gutem Deutsch oder Englisch verfasst wurde mit klarem Satzbau und gutem Sprachrhythmus, dass keine Rechtschreib- oder Grammatikfehlern im Text auftauchen und dass die Argumente der Autorin oder des Autors klar, logisch, verständlich und gut veranschaulicht dargestellt werden. Daneben sind aber auch gut lesbare Schriftbilder und ein angenehmes Layout hilfreich. Die Nutzung dieser L^AT_EX-Vorlage hilft der Schreiberin oder dem Schreiber dabei zumindest bei Letzterem: Sie umfasst gute, sofort nutzbare Designs und sie kümmert sich um viele typographische Details.

Abstract

It is not easy to write a thesis that does not only advance science, but that is also a pleasure to read. While the scientific contribution of a thesis is undoubtedly of greater importance, the impact of *writing well* should not be underestimated: If the person who grades a thesis finds no pleasure in the reading, that person are also unlikely to find pleasure in giving outstanding grades. A well-written text uses good German or English phrasing with a clear and correct sentence structure and language rhythm, there are no spelling mistakes and the author's arguments are presented in a clear, logical and understandable manner using well-chosen examples and explanations. In addition, a nice-to-read font and a pleasing layout are also helpful. The L^AT_EX class presented in this document helps with the latter: It contains a number of ready-to-use designs and takes care of many small typographical chores.

Danksagungen

This is the place where you can thank people and institutions, do not try to do this on the title page. The only exception is in case you wrote your thesis while working or staying at a company or abroad. Then you should use the Weitere_□Unterstützung key to provide a text (in German) that acknowledges the company or foreign institute. For instance, you could use texts like »Die Arbeit ist im Rahmen einer Tätigkeit bei der Firma Muster GmbH entstanden« or »Die Arbeit ist im Rahmen eines Forschungsaufenthalts beim Institut für Dieses und Jenes an der Universität Entenhausen entstanden«. Do not name and thank individual persons from the company or foreign institute on the title page, do that here.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Contributions of this Thesis	1
1.2	Related Work	1
1.3	Structure of this Thesis	1
2	Hauptteil	2
2.1	Motivation	2
2.2	Ziel	2
2.3	Notation	3
2.4	Modellvergleich	3
2.5	Grundlagen der Latent Dirichlet Allocation (LDA)	4
2.6	Daten	6
2.7	Ansätze	7
2.8	Auswertung	12
3	Conclusion	13

1

Einleitung

- 1.1 Contributions of this Thesis
- 1.2 Related Work
- 1.3 Structure of this Thesis

2

Hauptteil

2.1 Motivation

Die digitalisierte Welt generiert täglich riesige Mengen an neuen Informationen. Die Kapazitäten, die ein Mensch aufbringen kann, um solche Massen an Daten zu organisieren und zu verstehen, sind schon lange übertroffen. Topic Modeling (dt. Themenmodellierung) beschreibt eine Gruppe von Verfahren, die es ermöglichen, große elektronische Datensammlungen automatisiert zu durchsuchen, organisieren und zu verstehen. Es können Muster innerhalb der Daten entdeckt und Themen extrahiert werden. Dabei stellen Themenmodelle statistische Modelle dar, die Verwendung in der Inferenz abstrakter Themen in unsortierten Datenmengen finden. In einer Welt von exponentiell wachsenden Datenmengen finden Methoden der Themenmodellierung stetig eine breitere Anwendung. Bereits heute wird Themenmodellierung in vielen Bereichen der Wirtschaft, Wissenschaft und Informationstechnologie verwendet. Um semantische Folgerungen aus Datenmengen zu generieren, gibt es verschiedene Ansätze – in dieser Arbeit wird es um die ‚Latent Dirichlet Allocation‘ gehen. Dabei werden ähnliche Wörter, die in ähnlichen Kontexten vorkommen in einem Cluster gruppiert.

2.2 Ziel

Diese Arbeit wird die Theorie der Themenmodellierung anhand des Beispiels des Zweckverband Ostholstein (ZVO) implementieren und die bezüglichen Parameter im Sinne der Auswertung bewerten. Der ZVO erhält jährlich eine große Menge an Kundenanfrage. Diese werden momentan händisch an die jeweils zuständige Abteilung weitergeleitet. Der Prozess soll zukünftig automatisch durch einen Klassifikationsmechanismus funktionieren. Nach der Implementation eines LDA Algorithmus zur Inferenz verschiedener Abteilungen aus den Kundenanfragen, kann die momentan händische Kategorisierung bewertet werden. Diese Arbeit beschäftigt sich mit der Vorhersage der Qualität des Klassifikators, indem die Qualität der manuell erstellten Kategorien und Kundenanfrage-Gruppen untersucht und mit den Ergebnissen verschiedener Themenmodellierung verglichen wird. Das Ergebnis einer Themenmodellierung hängt stark von der Qualität der Daten ab, die sie als Input bekommt. Diese Daten durchlaufen eine Reinigungsphase,

bevor sie klassifiziert werden, um sie in eine gut zu verarbeitende Form zu bringen.

2.3 Notation

- \mathcal{K} ist die Anzahl der Themen in einem Topic-Modell \mathcal{M}
- Ein Modell \mathcal{M} repräsentiert den Korpus \mathcal{D}
- Eine Menge von Dokumenten ist ein Korpus \mathcal{D}
- Ein Dokument d eines Korpus ist eine Menge von \mathcal{K} -vielen Worten

2.4 Modellvergleich

Latent Dirichlet Allocation

Themenmodellierung besteht aus vielen Methoden, die meist verbreitete ist die „Latent Dirichlet Allocation (LDA)“, was als Bag of Word modelliert ist, also keine Kontextinformationen beinhaltet. Dieses Verfahren ist eine Weiterentwicklung des ‚PLSI‘, das durch zwei Dirichlet-Priors ergänzt wurde. LDA liegt ein generierender Prozess zugrunde, den zwei Dirichlet-Verteilungen maßgeblich beeinflussen: die Dokument-Themen Verteilung, die die Ausprägungen verschiedener Themen in einem Dokument beschreibt, und die Themen-Wörter Verteilung, die die Wahrscheinlichkeit beschreibt, dass ein bestimmtes Wort in einer gewissen Regularität in einem Themenbereich vorkommt. Dabei geht man davon aus, dass ein Dokument eine Verteilung von Themen ist, während ein Thema als eine Verteilung über Wörter betrachtet wird. Die Wahrscheinlichkeit, dass ein bestimmtes Dokument generiert wird, ist das Produkt der Wahrscheinlichkeiten der beiden Verteilungen mit den Wahrscheinlichkeiten zweier multinomialen Verteilungen, die erst zufällig Topics, wie in der Dirichlet-Verteilung definiert, auswählen und aus diesen dann, mithilfe der zweiten Dirichlet-Verteilung, Wörter aus diesen Topics herleiten, wodurch das Enddokument entsteht. Das Enddokument wird höchstwahrscheinlich stark von dem gegebenen Dokument abweichen, jedoch kann durch anpassen der Dirichlet-Verteilungen ein Optimierungsproblem formuliert werden, nach dem die Dirichlet-Verteilungen gesucht werden, die ein möglichst ähnliches Dokument generieren.

Latent Semantic Analysis (LSA)

Ein anderes verbreitetes Verfahren ist das „Latent Semantic Analysis“ (LSA), welches auf das Finden von sogenannten Hauptkomponenten in Dokumenten abzielt. Dadurch können sowohl ähnliche Wörter gefunden, als auch Textbereiche, die inhaltliche Überschneidungen mit einem bestimmten Begriff haben, aber das Wort selber nicht enthalten, gefunden werden. Die Methode basiert auf dem Prinzip der Singulärwertzerlegung (SVD). Als Ausgangslage wird aus einer Textsammlung eine Term-Dokument-Matrix erstellt. Diese Matrix wird in der SVD als Produkt von drei Matrizen dargestellt, von denen die mittlere eine Diagonalmatrix darstellt. Die Werte auf der Diagonalen lassen daraus die Topics der Textmenge ablesen. Auf das SVD Verfahren selbst hat der Entwickler wenig

Einfluss. Um Rauschen zu verhindern, kann jedoch die Anfangsmatrix mithilfe der term-frequency und inverse-document-frequency verbessert werden, was sich auf das Gesamtergebnis auswirkt. LSA stellt sich als ein attraktives Verfahren heraus, da es Synonyme besser erkennen kann, als LDA und wird heutzutage unter anderem intensiv in dem Bereich des Digital Marketings genutzt.


Non-Negative Matrix Factorization (NMF)

Ein weiteres Verfahren, das auch mit Matrizen funktioniert, wird „Non-Negative Matrix Factorization“ (NMF) genannt. Dabei wird eine Matrix, die Wörter auf Dokumente abbildet, in zwei Teilmatrizen faktorisiert. Die erste Teilmatrix stellt die Topics in Dokumenten, die zweite die Wörter in Topics dar. Dadurch kann Speicherplatz gespart, und Themen aufgedeckt werden. Das Verfahren beginnt mit zwei möglichen faktorisierten Matrizen und verbessert sich durch die Errorfunktion iterativ, bis das Ergebnis gut genug ist. Dabei werden die errechneten Werte mit der gegebenen Matrix verglichen und angepasst.

2.5 Grundlagen der Latent Dirichlet Allocation (LDA)

Latent Dirichlet Allocation ist ein grundlegendes und bekanntes Verfahren aus der natürlichen Sprachverarbeitung. Das Prinzip der Themenmodellierung basiert auf einer Menge an Dokumenten, die den Korpus darstellen. Dabei werden alle Dokumente als Menge von Wörtern angenommen, die als Bag of Words modelliert sind. Dabei hat weder die Reihenfolge, noch die Groß- und Kleinschreibung Einfluss auf das Ergebnis. Die Themen werden allein an der Vorkommenswahrscheinlichkeit der Wörter ohne Reihenfolgen- oder Kontextinformationen erkannt. Durch die Reduktion der Dimension wird die Effizienz gesteigert. Somit wird also jedes Dokument durch eine Verteilung der enthaltenen Wörter repräsentiert.

Eine Besonderheit bei der Themenerkennung mit LDA ist, dass die Anzahl der gesuchten Themen K vorgegeben werden muss. Oft ist diese vorher jedoch nicht bekannt und muss über Hilfsverfahren, wie der Perplexitätsberechnung ermittelt werden. Die Funktionsweise von LDA ist über folgende graphische Abbildung beschrieben:



Dabei beschreibt W als einzige nicht verborgene Variable eines von N Wörtern des Dokuments. Das Wort ist semantisch einem Thema Z zugeordnet. Das Thema wiederum hängt von der Themen-Verteilung θ des Dokuments ab, das als ein Element der M vorliegenden Dokumente betrachtet wird. Neben dem Thema, wird jedes Wort auch von der jeweiligen Thema-Wort-Verteilung der K Themen beeinflusst. Das Modell und dessen Verteilungen kann durch die Parameter α und β angepasst werden. α kann bestimmt die Intensität der Dokument-Themen-Verteilung, während β die der Themen-Wort-Verteilung beeinflusst. Bei einem großen α ist die Verteilung der Themen in einem Dokument ähnlicher. Zusätzlich werden bei LDA zwei Bedingungen verfolgt, die von den beiden Parametern beeinflusst werden können. Erstens strebt man für alle Wort eines bestimmten Dokuments so wenig zugeordnete Themen an, wie möglich. Zweitens soll ein Thema über so wenig relevante Wörter wie möglich verfügen. Die beiden Ziele stehen in einer Wechselbeziehung zueinander, da eine minimale Anzahl an vertretenen Themen in einem Dokument zu maximal vielen Wörtern in diesen Themen führt. Die minimale Anzahl an Themen wäre erreicht, wenn man alle Wörter eines Dokuments einem Thema zuweist. Dadurch verfügt das Thema jedoch über alle Wörter des Dokuments. α befindet sich in dem Bereich $[0, 1]$ mit sinnvollen Werten zwischen $[0.01, 0.1]$, während $\beta = 0.01$ durchschnittlich die besten Ergebnisse liefert. Große Werte führen zu einer Gleichverteilung, die wiederum eine Verschlechterung der Perplexität bedeutet. Somit bietet die Perplexität ein Mittel, um α und β optimal für die individuelle Anwendung zu finden.

Bei LDA werden zwei Verteilungen aus den Dokumenten $d \in \mathcal{D}$ und $k \in \mathcal{K}$ gelernt: die Dokument-Topic-Verteilung θ und die Topic-Wort-Verteilung ϕ . Dabei gibt die Dokument-Topic-Verteilung an, mit welcher Wahrscheinlichkeit das Dokument zu jedem Themen gehört. Die Topic-Wort-Verteilung berechnet die Wahrscheinlichkeit, dass ein Wort einem Thema angehört. $\mathcal{M} = \text{LDA}(\mathcal{D})$ beschreibt ein LDA Modell, das auf der Dokumentenmenge/Korpus \mathcal{D} trainiert wurde.

Der generative Prozess

Der Algorithmus hinter LDA generiert neue Dokumente mithilfe von Dirichletverteilungen $\text{Dir}(\gamma)$ und Multinomialverteilungen $\text{Multinom}(\delta)$. Die Verteilungen θ und ϕ werden errechnet, indem iterativ neue Dokumente über andere Verteilung generiert werden, bis das generierte Dokument die Anforderungen befriedigt, dann können die Verteilungen

abgelesen werden, mit denen das Dokument erstellt wurde. Der Prozess verläuft folgendermaßen:

1. Wähle ein θ als $Dir(\alpha)$
2. Wähle ein ϕ als $Dir(\beta)$
3. Für jedes Wort w and Stelle $i = 1, \dots, N$ im Dokument d :
 - 3.1 Wähle ein Thema $z_{d,i}$ als $Multinom(\theta_d)$
 - 3.2 Wähle ein Wort $w_{d,i}$ als $Multinom(\phi_{z_{d,i}})$

Somit kann der Algorithmus nun neue Dokumente erstellen und das Ergebnis durch die Parameter, wie Alpha und Beta, anpassen, bis das Ergebnis ähnlich genug zu dem Anfangsdokument ist. Dann ist die Verteilung der Themen in diesem Dokument bekannt. Bei der Anwendung von LDA für praktische Problemstellungen, geht LDA das Prinzip rückwärts durch, d.h. für bestehende Gruppen an Dokumenten werden Verteilungen gesucht, durch die das Dokument generiert hätte werden können.

$$P(w, z, \theta, \phi, \alpha, \beta) = \prod P(\theta, \alpha) \cdot \prod P(\alpha, \beta) \cdot \prod P(z,) \cdot \prod P(w | \phi) \quad (2.1)$$

Die Formel beschreibt die totale Wahrscheinlichkeit des LDA Modells. Sie setzt sich zusammen aus den Produkten der Dirichlet Verteilung der Topics und der Wörter zusammen mit den multinomialen Verteilungen der Themen und Wörter. Die Schwierigkeit des Algorithmus besteht in der Berechnung der θ -Verteilung der gegebenen Dokumente für latente Variablen. Dies lässt sich durch folgende Wahrscheinlichkeitsverteilung ausdrücken:

$$P(\theta, z | w, \alpha, \beta) = \frac{P(\theta, z, w | \alpha, \beta)}{P(w | \alpha, \beta)} \quad (2.2)$$

Die Formel berechnet die Wahrscheinlichkeit der Verteilung unter einem bestimmten Thema gegeben der α und β Parameter und dem bekannten Wort.

2.6 Daten

Die Daten liegen in folgendem Format vor:

2 Hauptteil

	filename	subject-message	Ablesung	Allgemeiner Schriftverkehr	BM-Beschwerden	KA-Kommunaler Abfall	MaKo-Klärfälle	ZSB-Aktionen	ZSB-BAV	Zählerdatenmanagement	ZSB-Forderungsmana
0	2015/11/14658664	zählerstände verbrauchsstellen kundennummer ma...	1	0	0	0	0	0	0	0	0
1	2015/11/14669252	eigentumsänderung niederschlagswasserbeseitigu...	0	0	0	0	0	1	0	0	0
2	2015/11/14848548	ovg urteil schreiben schmidt verbandsvorsteher...	0	0	0	0	0	0	0	0	0
3	2015/11/14844310	kontaktformular holding ggf kundennummer anrede...	0	0	0	0	0	0	0	0	0
4	2015/11/14789155	shop eutin kundennummer herrn gewerbe standort...	0	0	0	0	0	0	0	0	0
...
133040	2019/09/27562984 2013/12/10037247	überweisungsbeleg	0	1	0	0	0	0	0	0	0

Relevant für die Auswertung sind die subject-message und die jeweilige Abteilung. Die Tabelle verfügt über eine Matrix mit 18 Abteilungen, von denen pro subject-message eine mit einer 1 versehen ist. Dies beschreibt die Abteilung, der diese Anfrage manuell zugeordnet wurde. Die Daten in subject-message sind bereits bereinigt, also liegen vor, wie in diesem Beispiel, der Zeile 0:

```
In [9]: df.at[0, 'subject-message']
```

```
Out[9]: 'zählerstände verbrauchsstellen kundennummer markieren lieferantenwechsel anrede frau vorname rosemarie nachname h
orstmann straße ruschkamp plz ort scharbeutz telefonnummer mobilnummer faxnummer adresse ablesedatum datum zähler
zählerart erdgas zählernummer zählerstand zählerart wählen zählernummer zählerstand zählerart wählen zählernummer
zählerstand'
```

Um die Einträge in eine computer-lesbare Form zu verwandeln, muss ein Dictionary erstellt werden, dass alle Wörter auf eine Anzahl ihrer Vorkommen abbildet. Dafür müssen die Wörter als alleinige Listeneinträge einlesbar sein:

```
In [4]: df.at[0, 'subject-message'].split()
```

```
Out[4]: ['zählerstände',
'vebrauchsstellen',
'kundennummer',
'markieren',
'lieferantenwechsel',
'anrede']
```

Gibbs Sampling

Hellinger Distanz

Datenreinigung

Bevor eine Themenmodellierung auf Daten durchgeführt werden kann, müssen die Daten einem Prozess unterzogen werden. Dieser beginnt mit der Datenaquise, also der Akquirierung bestimmter relevanter Daten. Im Falle der ZVO bedeutet dies, dass es genügend Kundenanfragen gibt, die verarbeitet werden können. Wenn diese Daten bestehen, werden sie auf die relevanten Wörter reduziert, aus denen eine bedeutsame Inferenz von Informationen möglich ist, sodass unter anderem die sogenannten „Stop-Words“, also eine Menge von Verbindungswörtern entfernt werden. Ein anderer Schritt der Datenreinigung ist das Transponieren aller Wörter in kleine Buchstaben, um eine Einheitlichkeit

zu erlangen, da das Bag of Words Modell keine Reihenfolge mehr beachtet und somit große Satzanfänge irrelevant werden. Wenn die Daten in der gewünschten Form vorliegen, beginnt der Schritt des Featureengineerings. Für einen Computer sind Wörter nicht so leicht zu verarbeiten, wie Zahlen, weshalb in diesem Schritt eine Quantisierung der Wörter und Überführung dieser in eine zahlenbasierte Form vorgenommen wird. Dies kann zum Beispiel in Form eines Bag-of-Words Modells, Dictionary oder TF-IDF, also einer relativen Vorkommensauflistung verschiedener Wörter über Dokumente umgesetzt werden. Nachdem die Daten in eine für den Computer kompatiblen Form gebracht wurden, kann das Themenmodell entwickelt werden.

2.7 Ansätze

In diesem Abschnitt werden verschiedene Möglichkeiten implementiert und analysiert, wie LDA im Sinne der ZVO genutzt werden kann. Dabei ist die Zielfrage, wie am besten für ein unbekanntes Dokument die bestimmte Abteilung gefunden werden kann. Dafür müssen Korpora bestehen, die bereits durch Verteilung definiert sind, sodass die Dokument-Themen Verteilung für das neues Dokument inferiert werden kann. Wenn die Themenverteilung des neuen Dokuments gegeben ist, kann über Vergleiche der Verteilungen mit Dokumenten oder Durschnitten von Korpora eine Abteilung für das Dokument identifiziert werden.

Die Möglichkeiten, die sich für diesen Zweck ergeben sind folgende:

1. Alle Dokumente ergeben ein Korpus. Das neue Dokument wird mit dem gesamten Korpus verglichen und auf thematische Kompatibilität geprüft. Ein Gesamtbild der thematischen Aufteilung aller Dokumente kann eine mögliche effektivere Neuverteilung der Kategorien schlussfolgern.
2. Jede Abteilung stellt einen Korpus da, deren Verteilung mit der des neuen Dokuments verglichen wird. In diesem Fall hat jede der 18 Abteilungen eine Dokument-Themen Verteilung, die die Abteilung inhaltlich von den anderen unterscheidet. Die Wörter-Themen Verteilung ist für alle gleich, damit ein neues Dokument mit allen Abteilungsverteilungen verglichen werden kann. Dazu wird ein neues Dokument in jedem einzelnen Korpus integriert, um eine Dokument-Themen Verteilung für das neue Dokument auf Basis der gegebenen Wörter-Themen Verteilung zu inferieren.
3. Jede Abteilung stellt einen Korpus dar, deren Dokumente alle einzeln mit der Verteilung des neuen Dokuments verglichen werden, das dann quantitativ einer Abteilung zugeordnet wird. Die Wörter-Themen Verteilung ist gleich, während für jedes Dokument eine Dokument-Themen Verteilung errechnet wird. Wenn die Dokument-Themen Verteilung der bestehenden Dokumente und die des neuen Dokuments bereitstehen, können diese auf Ähnlichkeit überprüft werden. Da bereits bekannt ist, welcher Abteilung jedes Dokument angehört, stellen die Top X ähnlichsten Dokumente eine Verteilung der Abteilungen dar, denen das neue Dokument inhaltlich am ähnlichsten ist.

Möglichkeit 1 Groppe

Ziel dieser Untersuchung ist, der Vergleich der Themen, die sich durch ein LDA Modell ergeben mit den händisch eingeteilten Themen. Dafür wird ein Korpus auf allen Dokumenten generiert, der eine Themenverteilung erzeugt. Um herauszufinden, welches Dokument, zu welchem Thema gehört, werden die Themenverteilungen der einzelnen Dokumente inferiert. Die durch LDA erzeugte Themen werden mit den händisch geordneten Themen verglichen, indem Überschneidungen der enthaltenen Dokumente quantifiziert werden. Da LDA die Themen nicht benennen kann, sondern nur die Verteilung der Wörter auflistet, müssen die von LDA gefundenen Gruppen noch den händischen zugeordnet werden. Die Zuordnung, die in Summe die meisten Übereinstimmungen zwischen den Gruppen ergibt, stellt die realistischste Interpretation der LDA Themen dar. Das Ergebnis kann Aufschluss über die vorgegeben Themen geben. Bei einem perfekten Modell und optimaler Themeneinteilung müssten die Themen mit einer sehr hohen Überschneidungsrate eindeutig einteilbar sein.

Dabei werden zuerst alle Anfragedaten in einen String zusammengefügt, der als Grundlage für das Wörterbuch und den Korpus dient. Durch den Aufruf des LDA Modells wird der String in eine vorgegebene Anzahl an Themen eingeteilt, basierend auf häufig zusammen auftretenden Wörtern des Wörterbuchs.

Die Überschneidungen sind in einer Matrix aufgetragen, die für jedes Thema aus dem LDA Modell die Anzahl der Überschneidungen mit jedem manuell erzeugten Thema speichert. Mit einer Max-Funktion wird das maximale Element aus jeder Zeile gefunden und dessen Index in einer Liste gespeichert. Dieser Index repräsentiert die Abteilung, mit der das jeweilige Thema des LDA Modells am wahrscheinlichsten zugeordnet wäre. Der Liste lässt sich folgend interpretieren:

```
maxmatrix = [9, 10, 0, 9, 10, 10, 0, 10, 10, 0, 1, 2, 1, 9, 10, 9, 10,
9]
```

Eine optimale Zuordnung ist erreicht, wenn alle Zahlen von Eins bis 18 ohne Duplikate in der Liste in einer beliebigen Reihenfolge vorkommen. Das würde bedeuten, dass einem Thema von LDA genau ein Thema der ZVO am wahrscheinlichsten zugeordnet ist. In der Liste wird jedoch deutlich, dass viele Themen des LDA Modells mit dem 9. und 10. Thema der ZVO kompatibel wären. Somit ist zumindest keine optimale Zuordnung des Modellergebnisses möglich, was entweder auf die Aufteilung der Themen oder das Modell zurückzuführen ist.

Möglichkeit 2 Felix

Hier wird ein neues Dokument einer Abteilung zugeordnet. Dabei wird über den Ähnlichkeitsoperator zwischen der Verteilung des neuen Dokuments und der des Abteilungskorpus entschieden, wie passend das Dokument und die jeweilige Abteilung sind. Die Ähnlichkeit kann entweder an der durchschnittlichen Dokument-Themenverteilung des

ganzen Korpus‘ abgelesen werden oder jedes Dokument wird einzeln mit dem unbekannten Dokument verglichen. Bei letzterem werden dann die Dokumente pro Abteilung gezählt und abteilungsübergreifend verglichen. Dafür müssen zuerst alle Anfragen, die einer Abteilung zugeordnet wurden in einen Text vereinigt werden, aus dem dann der Korpus entstehen kann. Dies wird mit der folgenden Methode implementiert:

```
In [105]: for a in range(0,18):
          globals()['abt%s' % a] = ''

          for c in range(0,18):
            for x in range(0,133040):
              if(df.iloc[x,c+2]==1):
                globals()['abt%s' % c] += df.at[x, 'subject-message']
            globals()['abt%s' % c] = globals()['abt%s' % c].split()
```

Aus dem „Wenn“-Statement ist zu erkennen, dass nur die subject-messages zum „result0“ hinzugefügt werden, die in der Tabelle bei Abteilung 0 eine 1 haben. Das Ergebnis wird dann direkt in einzelne Listenelemente unterteilt, damit ein Dictionary erstellt werden kann. Für jede Abteilung wird dann, wie oben bereits durchgeführt, ein Korpus generiert und dessen durchschnittliche Verteilung errechnet:

```
In [107]: for x in range(0,18):
          dictionary = corpora.Dictionary([globals()['abt%s' % x]])
          temp = dictionary[0]
          id2word = dictionary.id2token
          corpus = [dictionary.doc2bow(text) for text in [globals()['abt%s' % x]]]
          globals()['lda%s' % x] = LdaModel(corpus, num_topics=18, id2word = id2word)
```

Wenn die Verteilung der Themen des Korpus gegeben ist, kann nun ein neues Dokument in diesen Korpus integriert werden und auf Basis der Wort-Themenverteilung eine Dokument-Themenverteilung des unbekannten Dokuments errechnet werden.

Ein unbekanntes Dokument muss mit jeder Abteilung verglichen werden. Wie mache ich das?

Alternativ zu Möglichkeit 1 (Erster Versuch)

Das Ziel ist die Generierung einer Themenverteilung über alle Dokumente im Korpus. Diese könnte Aufschluss über die generelle Kategorien der Abteilungen geben. Dafür müssen zuerst alle Daten in einen großen Korpus vereinigt werden, das ist in der Methode „returnAll()“ implementiert. Danach wird diese in eine Liste aufgeteilt und in ein Dictionary verwandelt. Diese wird dann genutzt um mit der „gensim.models.LdaMulticore()“-Methode in einen LDA Modell verwandelt wird. Für dieses Modell wurde die Themenanzahl auf 18 gesetzt, da dies die aktuelle Anzahl der Themen bei dem ZVO ist.

2 Hauptteil

```
In [11]: #Zusammenfügen aller Anfragen in eine große Datenmenge
def returnall(data):
    collected = []
    print('Step 1: started merging')
    for x in range(0,133844):
        collected = data.at[x, 'subject-message']
    print('Step 2: finished merging')
    return collected

#Zusammengefügte Daten in eine Liste splitten
splittedata = returnall(data).split()
print('Step 3 finished splitting')

# Testausgabe nach Split
for x in range(1,5):
    # print(splittedata[x])

# Dictionary für Topic-Wortverteilung
wordIds = corpora.Dictionary(splittedata)
print('Step 4: dictionary created')

# Definition Korpus
var = splittedata
corpus = wordIds.doc2bow(text) for text in var
#print(corpus[1][0][1:30])

#LDA MODEL mit Themen-Wortverteilung pro Topic wiedergabe
num_top = 18

lda_mod = gensim.models.LdaMulticore(corpus=corpus, id2word=wordIds, num_topics=num_top, alpha=0.8)

print(lda_mod.print_topics())
doc_lda = lda_mod[corpus]

print('Step 5 Lda Model generated')

#Topic-Distribution
```

```
Step 1: started merging
Step 2: finished merging
Step 3 finished splitting
Step 4: dictionary created
[[0,
  '0.012*\"zweckverband\" + 0.010*\"betreff\" + 0.009*\"danken\" + '
  '0.008*\"ostholstein\" + 0.008*\"sierksdorf\" + 0.008*\"nachricht\" + 0.007*\"and\" + '
  '0.007*\"email\" + 0.007*\"the\" + 0.006*\"gesine\"'),
 (1,
  '0.012*\"zweckverband\" + 0.010*\"ostholstein\" + 0.010*\"sierksdorf\" + '
  '0.009*\"nachricht\" + 0.008*\"betreff\" + 0.008*\"the\" + 0.007*\"danken\" + '
  '0.007*\"lübeck\" + 0.006*\"gmbh\" + 0.006*\"hyperlink\"'),
 (2,
  '0.013*\"ostholstein\" + 0.012*\"sierksdorf\" + 0.011*\"nachricht\" + '
  '0.011*\"zweckverband\" + 0.009*\"betreff\" + 0.009*\"lübeck\" + 0.008*\"danken\" + '
  '0.008*\"the\" + 0.007*\"frau\" + 0.006*\"homepage\"'),
 (3,
  '0.012*\"sierksdorf\" + 0.011*\"ostholstein\" + 0.011*\"zweckverband\" + '
  '0.011*\"nachricht\" + 0.009*\"the\" + 0.007*\"danken\" + 0.007*\"hyperlink\" + '
  '0.006*\"sitzen\" + 0.006*\"email\" + 0.006*\"körperschaft\"'),
 (4,
  '0.013*\"sierksdorf\" + 0.013*\"ostholstein\" + 0.011*\"danken\" + '
  '0.011*\"zweckverband\" + 0.009*\"frau\" + 0.009*\"the\" + 0.009*\"betreff\" + '
  '0.008*\"nachricht\" + 0.006*\"hra\" + 0.006*\"email\"'),
 (5,
  '0.012*\"zweckverband\" + 0.010*\"ostholstein\" + 0.009*\"the\" + '
  '0.009*\"sierksdorf\" + 0.008*\"email\" + 0.008*\"betreff\" + 0.008*\"danken\" + '
  '0.007*\"nachricht\" + 0.007*\"sitzen\" + 0.006*\"hyperlink\"'),
 (6,
  '0.013*\"sierksdorf\" + 0.012*\"zweckverband\" + 0.011*\"ostholstein\" + '
  '0.010*\"danken\" + 0.007*\"nachricht\" + 0.007*\"frau\" + 0.007*\"the\" + '
  '0.007*\"email\" + 0.006*\"betreff\" + 0.006*\"and\"'),
 (7,
  '0.011*\"nachricht\" + 0.010*\"zweckverband\" + 0.010*\"ostholstein\" + '
  '0.008*\"betreff\" + 0.007*\"danken\" + 0.007*\"email\" + 0.007*\"the\" + '
  '0.007*\"lübeck\" + 0.007*\"sierksdorf\" + 0.007*\"frau\"'),
 (8,
  '0.012*\"ostholstein\" + 0.010*\"sierksdorf\" + 0.009*\"zweckverband\" + '
  '0.009*\"the\" + 0.007*\"betreff\" + 0.007*\"frau\" + 0.006*\"danken\" + '
  '0.006*\"nachricht\" + 0.006*\"email\" + 0.006*\"datum\"'),
 (9,
  '0.013*\"ostholstein\" + 0.011*\"sierksdorf\" + 0.010*\"zweckverband\" + '
  '0.009*\"nachricht\" + 0.008*\"the\" + 0.008*\"betreff\" + 0.007*\"frau\" + '
  '0.007*\"danken\" + 0.006*\"hyperlink\" + 0.006*\"wagenring\"'),
 (10,
  '0.011*\"zweckverband\" + 0.009*\"ostholstein\" + 0.009*\"the\" + '
  '0.009*\"sierksdorf\" + 0.008*\"nachricht\" + 0.008*\"betreff\" + '
  '0.008*\"email\" + 0.007*\"frau\" + 0.006*\"lübeck\"'),
 (11,
  '0.012*\"sierksdorf\" + 0.011*\"ostholstein\" + 0.010*\"the\" + '
  '0.008*\"zweckverband\" + 0.008*\"email\" + 0.007*\"nachricht\" + 0.007*\"danken\" + '
  '0.007*\"and\" + 0.006*\"lübeck\" + 0.006*\"frau\"'),
 (12,
  '0.012*\"sierksdorf\" + 0.010*\"the\" + 0.010*\"zweckverband\" + 0.010*\"nachricht\" + '
  '0.009*\"ostholstein\" + 0.009*\"betreff\" + 0.008*\"danken\" + 0.007*\"email\" + '
  '0.007*\"information\" + 0.006*\"lübeck\"'),
 (13,
  '0.011*\"zweckverband\" + 0.011*\"ostholstein\" + 0.011*\"nachricht\" + '
  '0.009*\"the\" + 0.008*\"sierksdorf\" + 0.008*\"betreff\" + 0.007*\"frau\" + '
  '0.007*\"lübeck\" + 0.006*\"and\" + 0.006*\"danken\"'),
 (14,
  '0.011*\"sierksdorf\" + 0.011*\"danken\" + 0.010*\"zweckverband\" + '
  '0.010*\"betreff\" + 0.009*\"ostholstein\" + 0.008*\"the\" + 0.008*\"nachricht\" + '
  '0.007*\"frau\" + 0.007*\"and\" + 0.006*\"lübeck\"'),
 (15,
  '0.011*\"ostholstein\" + 0.011*\"zweckverband\" + 0.010*\"the\" + '
  '0.009*\"sierksdorf\" + 0.008*\"nachricht\" + 0.008*\"danken\" + 0.008*\"betreff\" + '
  '0.006*\"frau\" + 0.006*\"lübeck\" + 0.006*\"email\"'),
 (16,
  '0.010*\"nachricht\" + 0.010*\"zweckverband\" + 0.009*\"sierksdorf\" + '
  '0.009*\"betreff\" + 0.008*\"the\" + 0.008*\"ostholstein\" + 0.007*\"frau\" + '
  '0.007*\"email\" + 0.006*\"danken\" + 0.006*\"homepage\"'),
 (17,
  '0.015*\"ostholstein\" + 0.012*\"sierksdorf\" + 0.009*\"zweckverband\" + '
  '0.009*\"the\" + 0.007*\"nachricht\" + 0.007*\"betreff\" + 0.007*\"and\" + '
  '0.006*\"email\" + 0.006*\"frau\" + 0.006*\"danken\"')]
Step 5 Lda Model generated
```

Der Output zeigt eine Liste mit 18 Elementen. Jedes Element beschreibt die Wortverteilung in einem der 18 Themen. Dabei kann LDA das Thema nicht semantisch benennen, sondern nur Cluster an häufig zusammen vorkommenden Wörtern formen. Daher kommt auch der „Latent“-Teil in der Benennung. Neben der Themen-Wortverteilung ist die Dokument-Themenverteilung von Interessen, also wie häufig kommt jedes Topic in der Gesamtmenge aller Anfragedaten vor. Diese Information errechnet man sich, indem man die folgende Methode aufruft:

```
In [44]: all_topics = lda_mod.get_document_topics(corpus, per_word_topics=True)

print(doc_topics)
```

```
[[0, 0.018413449], (1, 0.06065566), (2, 0.06351237), (3, 0.014391888), (4, 0.11020222), (5, 0.12415801), (6, 0.030
072724), (7, 0.014063389), (8, 0.013174435), (10, 0.15869582), (11, 0.032077530), (12, 0.027906904), (13, 0.114994
764), (14, 0.051106744), (15, 0.042404146), (16, 0.09394227), (17, 0.026795233)]
```

Aus dieser Ausgabe wird nun ersichtlich, wie wahrscheinlich es ist, dass ein bestimmtes Thema in den Daten vorkommt. Das 10. Thema ist mit 15,9% das am häufigsten Vorkommende Thema und damit sind die Wörter „zweckverband“, „ostholstein“ und „sierksdorf“ die am stärksten vertretenen Wörter im Gesamtkorpus. Dieses Ergebnis überrascht nur bedingt, da dies der Name der Organisation ist und dementsprechend häufig in Anfragen vorkommt.

Wenn man den gleichen Quelltext mit einer geringeren Themenanzahl aufruft, kommt man auf ein ähnliches Ergebnis, hier mit Beispiel 4:

2 Hauptteil

```
In [32]: #Zusammenfügen aller Anfragen in eine große Datenmenge
def returnAll(data):
    collected2 = []
    print('Step 1: started merging')
    for x in range(0,133844):
        collected2 = data.at[x, 'subject-message']
        print('Step 2: finished merging')
    return collected2

#Zusammengefügte Daten in eine Liste splitten
splitData2 = returnAll(df).split()
print('Step 3 finished splitting')

# Testausgabe nach Split
# for x in range(1,5):
#     print(splitData[x])

# Dictionary für Topic-Wortverteilung
wordID2 = corpora.Dictionary([splitData2])
print('Step 4: dictionary created')

# Definition Korpus
var2 = [splitData2]
corpus2 = [wordID2.doc2bow(text) for text in var2]
#print(corpus[1][0][1:30])

#LDA MODEL mit Themen-Wortverteilung pro Topic Wiedergabe
num_top2 = 4

lda_mod2 = gensim.models.LdaMulticore(corpus=corpus, id2word=wordID2, num_topics=num_top2, alpha=0.8)

pprint(lda_mod2.print_topics())
doc_lda2 = lda_mod2[corpus2]

print('Step 5: Lda Model generated')

# Dokument-Themenverteilung ausgeben
bow2 = lda_mod2.doc2bow(splitData) # convert to bag of words format first
doc_topics2, word_topics2, phi_values2 = lda_mod2.get_document_topics(bow2, per_word_topics=True)

word_topics

all_topics2 = lda_mod2.get_document_topics(corpus2, per_word_topics=True)
print(doc_topics2)
print('Step 6: Dokument-Themenverteilung finished')

Step 1: started merging
Step 2: finished merging
Step 3 finished splitting
Step 4: dictionary created
[[0,
  '0.011*nachricht" + 0.010*ostholstein" + 0.009*danken" + '
  '0.009*sierksdorf" + 0.008*zweckverband" + 0.007*the" + 0.007*betreff" + '
  '0.007*frau" + 0.007*this" + 0.006*email"',
  (1,
    '0.012*sierksdorf" + 0.010*the" + 0.010*ostholstein" + '
    '0.009*zweckverband" + 0.008*nachricht" + 0.008*betreff" + 0.007*danken" '
    ' + 0.006*frau" + 0.006*and" + 0.006*strohmer"',
    (2,
      '0.012*ostholstein" + 0.012*sierksdorf" + 0.012*zweckverband" + '
      '0.009*danken" + 0.008*betreff" + 0.007*nachricht" + 0.007*frau" + '
      '0.007*the" + 0.007*email" + 0.006*lübeck"',
      (3,
        '0.012*zweckverband" + 0.011*ostholstein" + 0.010*nachricht" + '
        '0.010*sierksdorf" + 0.009*the" + 0.008*danken" + 0.007*betreff" + '
        '0.007*lübeck" + 0.006*frau" + 0.006*email"')]]
Step 5: Lda Model generated
[[0, 0.1640083], (1, 0.19620994), (2, 0.3637842), (3, 0.27551556)]
Step 6: Dokument-Themenverteilung finished
```

Wieder hat das meistvertrene Thema die Wörter „Zweckverband“, „sierksdorf“ und „ostholstein“ als häufigste vorkommende Elemente. Als Einflussfaktor dient die Dirichlet Variable Alpha, die beeinflusst, wie stark die Wahrscheinlichkeitsunterschiede zwischen den einzelnen Werten ist. Im vorherigen Beispiel war Alpha 0,8 von 1.0. Im folgenden ist es 0,2 von 1.0:

```
Step 1: started merging
Step 2: finished merging
Step 3 finished splitting
Step 4: dictionary created
[[0,
  '0.013*ostholstein" + 0.013*zweckverband" + 0.010*sierksdorf" + '
  '0.009*nachricht" + 0.009*betreff" + 0.008*frau" + 0.008*danken" + '
  '0.007*the" + 0.006*lübeck" + 0.006*homepage"',
  (1,
    '0.012*ostholstein" + 0.011*sierksdorf" + 0.009*zweckverband" + '
    '0.009*the" + 0.009*danken" + 0.008*nachricht" + 0.007*betreff" + '
    '0.007*email" + 0.006*and" + 0.006*lübeck"',
    (2,
      '0.012*sierksdorf" + 0.011*zweckverband" + 0.009*the" + 0.009*nachricht" '
      ' + 0.009*ostholstein" + 0.008*betreff" + 0.006*danken" + 0.006*frau" + '
      '0.006*hyperlink" + 0.006*email"',
      (3,
        '0.011*sierksdorf" + 0.010*zweckverband" + 0.009*ostholstein" + '
        '0.009*nachricht" + 0.009*danken" + 0.009*the" + 0.008*betreff" + '
        '0.007*email" + 0.007*frau" + 0.006*lübeck"')]]
Step 5: Lda Model generated
[[0, 0.31668642], (1, 0.29446924), (2, 0.1640696), (3, 0.22477475)]
Step 6: Dokument-Themenverteilung finished
```

Was bringt mir das?

Möglichkeit 3 ??

2.8 Auswertung

Quellcode

Perplexität

ZVO

3

Conclusion

...